

Universidad de Cundinamarca

Programa académico: Ingeniería de Sistemas y computación

Espacio académico: Minería de Datos

INFORME TÉCNICO

Proceso ETL de extracción y limpieza con SSIS

*Proyecto: **Wildfire Data Mining** (Análisis de incendios forestales) — escalas globales, nacional (Colombia) y regional (Cundinamarca)*

Integrantes

Laura Valentina Bautista Vargas

Sergio Luis Gómez Ramírez

Camila Parra Berrio

Sara Vargas Carreño

Docente: Édison Gustavo Cañón Varela

Fecha: 29 de septiembre de 2026

0 Introducción


El presente informe documenta, paso a paso y con evidencia visual, la construcción del paquete ETL (Extract, Transform, Load) de la Etapa 3 del proyecto, desarrollado en SQL Server Integration Services (SSIS) sobre Visual Studio. El paquete toma como insumo el dataset consolidado en la Etapa 1 (incendios_ideam_2010_2024.csv, 40.010 registros) y aplica las reglas de tratamiento diagnosticadas en la Etapa 2.

Objetivo general. Diseñar e implementar un flujo ETL trazable que cargue los datos crudos en una zona de staging, los depure mediante reglas técnicas y de negocio, y separe los registros aceptados de aquellos que requieren revisión, dejando constancia de cada ejecución en una tabla de control de lotes.

Objetivos específicos

- Configurar el entorno de desarrollo (Visual Studio + extensión de Integration Services) y la conexión a la base de datos WildfireDW.
- Orquestrar el proceso en un Control Flow de cinco tareas: Inicio, Extracción, Limpieza, Verificación y Cierre.
- Cargar el archivo plano sin alterar su contenido en la tabla de staging stg_incendios, agregando campos de trazabilidad.
- Aplicar limpieza de texto, homologación contra catálogo, conversión de tipos, reglas de negocio y eliminación de duplicados.
- Registrar los conteos de filas recibidas, aceptadas y en revisión en la tabla control_lote.

1 Entorno y conexión




PASO 1.1

Instalar la extensión SSIS

- Extensions → Manage Extensions, buscar "integration".
- Instalar **SSIS Projects 2022+** (Microsoft, v2.2).
- Ejecutar el instalador descargado (~512 MB).

✓ **Resultado: plantilla Integration Services y SSIS Toolbox disponibles.**




PASO 1.2

Connection Manager OLE DB

- Clic derecho en Connection Managers → **New OLE DB Connection.**
- Una sola conexión, reutilizada por todo el paquete.

✓ **Resultado: conexión visible en el panel inferior del diseñador.**



PASO 1.3


Parámetros de la conexión

- **Provider:** Microsoft OLE DB Driver for SQL Server.
- **Server:** nombre del servidor.
- **Initial catalog:** WildfireDW.
- **Test Connection** → OK.

Decisión técnica: se empezó en un hosting gratuito (somee.com), pero su límite de 30 MB no soporta varios lotes de 40.010 filas. Se migró a SQL Server Express local con autenticación de Windows.

✓ **Resultado: conexión probada con éxito.**

2 Control Flow: tareas del lote



PASO 2.1

Execute SQL Task “Inicio”


- Inserta un lote **ABIERTO** en control_lote.
- **ResultSet = Single row** → guarda el ID en User::IdLote.

Verificación: cuenta filas de cada destino y las escribe en control_lote. **Cierre:** marca el lote COMPLETADO + fecha fin.

Clave: con OLE DB los parámetros van por posición (0, 1, 2...), no por nombre.

✓ **Resultado:** cada ejecución queda identificada por su IdLote.

3 Data Flow “Extracción”




PASO 3.1

Flat File Connection

- Conexión CSV_Incendios.
- Codificación **UTF-8**, encabezados en la primera fila.

✓ **Resultado: SSIS reconoce la estructura del CSV.**




PASO 3.2

Flat File Source

- Arrastrar **Flat File Source** al Data Flow.
- Asociarlo a CSV_Incendios.

✓ **Resultado: origen conectado al archivo de 40.010 filas.**




PASO 3.3

Selección de columnas

De 36 columnas se dejan las **7** con problemas de la Etapa 2: ANIO MES FECHA_REGISTRO DEPARTAMENTO MUNICIPIO AREA_TOTAL_HA FUENTE_HOJA

✓ **Resultado: menos memoria y proceso enfocado.**




PASO 3.4

Derived Column: trazabilidad

Crea las 3 columnas NOT NULL de staging que no vienen en el CSV:

Columna	Expresión
IdLote	(DT_I4)@[User::IdLote]
NombreArchivo	@[User::NombreArchivo]
ClaveFila	archivo + hoja + año + mes + depto. + área

✓ Resultado: cada fila sabe de qué lote y archivo viene.




PASO 3.5

OLE DB Destination

- Tabla [dbo].[stg_incendios].
- Table or view – fast load.
- Table lock y Check constraints activos.

✓ Resultado: destino de staging configurado.



PASO 3.6

Mapeo de columnas


Se mapean a mano al sufijo “**Texto**” (IdStaging y FechaCarga en <ignore>):

CSV	Staging
ANIO / MES	AnioTexto / MesTexto
FECHA_REGISTRO	FechaRegistroTexto
DEPARTAMENTO / MUNICIPIO	DepartamentoTexto / MunicipioTexto
AREA_TOTAL_HA	AreaTotalHaTexto
FUENTE_HOJA	FuenteHoja

PASO 3.7 · EVIDENCIA


Ejecución de la Extracción

Ejecución en modo depuración: los tres componentes terminan en verde.



✓ Resultado: 40.010 filas CSV → staging, sin pérdidas.

4 Data Flow “Limpieza”




PASO 4.1

OLE DB Source

- Lee [dbo].[stg_incendios] desde WildfireDW.

✓ **Resultado: flujo alimentado desde staging.**




PASO 4.2

Derived Column: limpieza de texto

Nueva columna	Expresión
DepartamentoClave	UPPER(TRIM(DepartamentoTexto))
MesClave	UPPER(TRIM(MesTexto))

Límite: no corrige tildes (“BOLIVAR” ≠ “BOLÍVAR”). Por eso sigue el Lookup contra catálogo.




PASO 4.3

Lookup: homologar departamento

- Full cache (catálogo pequeño).
- Une DepartamentoClave ↔ ClaveNormalizada.
- Devuelve CodigoDepartamento y Departamento.
- Sin coincidencia → **No Match Output**.

✓ **Resultado: departamentos unificados; los no reconocidos van a revisión.**




PASO 4.4

Data Conversion: tipos finales

Salida	Tipo	Si falla
AreaTotalHa	DT_NUMERIC(12)	Redirect row
Anio	DT_INT2	Redirect row
FechaRegistro	DT_DBDATE	Ignore failure

✓ **Resultado: texto convertido a número y fecha.**




PASO 4.5

Manejo de errores diferenciado

- Área y año inválidos → a revisión.
- Fecha inválida → queda en NULL y la fila sigue.

Error técnico ≠ regla de negocio: “-2” sí convierte a número; el área negativa se rechaza en el Conditional Split.




PASO 4.6

Conditional Split: reglas de negocio

#	Salida	Condición
1	SinFechaNiUbicacion	ISNULL() en año, mes, fecha o depto.
2	AreaNegativa	AreaTotalHa < 0
—	ReglasOk	por defecto → Sort

✓ Resultado: solo las filas válidas continúan.




PASO 4.7

Sort: eliminar duplicados

- Ordena por Departamento, Municipio, Fecha y Área.
- **Remove rows with duplicate sort values.**

Efecto: al usar el departamento ya homologado, detecta duplicados escritos distinto en el origen.

✓ **Resultado: un solo registro por evento.**



PASO 4.9

Destinos finales

Destino	Viene de
incendios_limpios	Sort
incendios_revision	Union All


Ambos en modo **fast load**. [Insertar capturas de Mappings de ambos destinos]

5 Verificación de la ejecución

EVIDENCIA

Consulta de la bitácora

SELECT * FROM dbo.control_lote; — SSMS sobre (local)\SQLEXPRESS



IdLote	NombreArchivo	Iteracion	Estado	FechaInicio	FechaFin	FilasRecibidas	FilasAceptadas	FilasDuplicadas	FilasRevision	Observaciones
1	incendios_ideam_2010_2024.csv	1	COMPLETADO	2026-09-23 22:28:30.6002510	2026-09-23 22:28:31.7500829	40010	0	NULL	0	NULL
2	incendios_ideam_2010_2024.csv	1	COMPLETADO	2026-09-23 23:05:37.8530719	2026-09-23 23:05:40.6432269	40010	0	NULL	0	NULL

IdLote	Estado	Inicio	Fin	Recibidas	Aceptadas	Revisión
1	COMPLETADO	2026-09-23 22:28:30	22:28:31	40.010	0	0
2	COMPLETADO	2026-09-23 23:05:37	23:05:40	40.010	0	0

✓ Resultado: dos lotes registrados y cerrados; 40.010 filas recibidas en cada uno.

6 Conclusiones

Trazabilidad completa

control_lote + IdLote + ClaveFila indican archivo, lote y fila de cada registro.

Error técnico ≠ regla de negocio

Data Conversion atrapa fallos de tipo; Conditional Split aplica reglas del dominio.

Ningún registro se pierde

Toda excepción va a incendios_revision con su motivo, sin detener el paquete.

Catálogo necesario

TRIM/UPPER no resuelve tildes; el Lookup homologa los departamentos.