

R1 · Del problema a los datos

Primer entregable del proyecto de Minería de Datos

Problema → preguntas → necesidades de información → fuentes → dataset → documentación en Flask

¿Qué buscamos en R1?

Antes de aplicar algoritmos debemos entender qué queremos descubrir.

1. Comprender

Interpretar el problema asignado y delimitar su alcance.

2. Preguntar

Convertir el problema en preguntas que puedan responderse con datos.

3. Conseguir datos

Identificar, justificar y documentar fuentes adecuadas.

4. Conocer los datos

Describir variables, estructura, procedencia y calidad inicial.

De un problema real a un problema de datos

Un problema real describe una situación; un problema de datos define qué evidencia necesitamos para analizarla.

Ejemplo: “En una ciudad aumentaron los accidentes de tránsito”.

Pregunta de datos: ¿qué factores están asociados con la ocurrencia y gravedad de los accidentes?

Datos posibles: fecha, hora, ubicación, clima, tipo de vía, vehículo, gravedad, condiciones del entorno.

Regla: no comenzar buscando algoritmos. Primero se define qué queremos conocer.

Pregunta principal y preguntas secundarias

Pregunta principal

Resume el propósito analítico del proyecto. Debe ser clara, delimitada y susceptible de responderse mediante datos.

Preguntas secundarias

Descomponen el problema. Orientan qué variables, periodos, poblaciones, relaciones y patrones debemos buscar.

Evitar

Preguntas demasiado generales, opiniones sin datos, preguntas cuya respuesta ya está contenida directamente en el enunciado.

¿Qué datos necesitamos?

Cada pregunta debe traducirse en necesidades concretas de información.

Identifique entidades: personas, lugares, eventos, productos, instituciones, transacciones, etc.

Identifique atributos: edad, fecha, categoría, ubicación, cantidad, estado, valor, duración...

Determine cobertura: periodo, zona geográfica, población y nivel de detalle.

Distinga entre datos deseables y datos realmente disponibles.

Una variable solo debe incorporarse si existe una razón para analizarla.

Tipos de recolección de datos

Primaria

Datos obtenidos de primera mano por el equipo: encuestas, entrevistas, observación, experimentos, sensores u otros mecanismos.

Secundaria

Datos previamente recolectados por una fuente externa: entidades públicas, organizaciones, empresas, repositorios o investigaciones.

Terciaria

Datos adquiridos mediante fuentes que recopilan o integran información de terceros, como proveedores o agregadores de datos.

Una misma investigación puede combinar varios tipos de fuentes.

¿Cómo evaluar una fuente de datos?

Pertinencia

¿Los datos realmente permiten responder nuestras preguntas?

Confiabilidad

¿Quién produce los datos? ¿Existe metodología o documentación?

Actualidad

¿El periodo disponible es adecuado para el problema?

Cobertura

¿Hay suficientes registros, variables y representatividad?

Además: revisar licencia/condiciones de uso, formato, frecuencia de actualización y posibilidad de reproducir la descarga.

Unidad de análisis, registro y variable

Unidad de análisis

Elemento sobre el cual queremos obtener conocimiento. Ej.: accidente, municipio, paciente, venta.

Registro

Una observación o fila del conjunto de datos.

Variable

Característica medida para cada registro. Ej.: fecha, cantidad, categoría, temperatura.

Tipos de variables

Categóricas

Nominales: categorías sin orden.
Ordinales: categorías con orden.

Numéricas

Discretas: conteos. Continuas: mediciones que pueden tomar valores dentro de un intervalo.

Temporales / espaciales

Fechas, horas, coordenadas, zonas y otras variables que requieren tratamiento particular.

Reconocer correctamente el tipo de variable condicionará las visualizaciones, transformaciones y algoritmos de entregables posteriores.

Diccionario de datos

El dataset sin contexto no es suficiente.

Por cada variable se debe documentar:

- Nombre del campo.

- Descripción y significado.

- Tipo de dato.

- Unidad o dominio de valores.

- Fuente/procedencia.

- Ejemplo de valor.

- Observaciones o restricciones.

El diccionario permitirá que otra persona comprenda el dataset sin depender de explicaciones verbales del grupo.

Calidad inicial de los datos

Compleitud

¿Qué porcentaje de datos está ausente?

Unicidad

¿Existen registros duplicados?

Consistencia

¿Los valores respetan formatos y reglas?

Validez

¿Los valores están dentro de dominios posibles?

En R1 se diagnostican los problemas; la limpieza profunda se realizará en un entregable posterior.

Trazabilidad y reproducibilidad

Siempre debe ser posible responder: ¿de dónde salió este dato?

Conservar la fuente original y registrar fecha de consulta/descarga.

No modificar el archivo original; trabajar sobre copias o procesos reproducibles.

Documentar filtros aplicados durante la adquisición.

Registrar integraciones entre múltiples fuentes.

Cuando corresponda, documentar limitaciones, sesgos y restricciones del conjunto de datos.

Flask será la bitácora técnica del proyecto

Desde R1 cada grupo debe construir su aplicación Flask.

El primer módulo debe documentar:

- Problema asignado y contexto.

- Pregunta principal y preguntas secundarias.

- Necesidades de información.

- Fuentes y tipo de recolección.

- Descripción del dataset.

- Diccionario de datos.

- Diagnóstico inicial de calidad.

- Limitaciones encontradas.

En los siguientes entregables la misma aplicación crecerá; no se reemplaza por documentos aislados.

Estructura mínima de la página R1

Problema

Contexto + pregunta principal + preguntas secundarias.

Recolección

Fuentes primarias/secundarias/terciarias y justificación.

Dataset

Cantidad de registros, variables, cobertura y procedencia.

Calidad

Diagnóstico inicial, limitaciones y observaciones.

Agregar además el diccionario de datos y evidencias visuales relevantes. La página debe poder entenderse sin una exposición oral.

Actividad inicial en clase

Con el problema asignado, el grupo debe responder:

1. ¿Qué queremos descubrir?
2. ¿Cuál sería nuestra pregunta principal?
3. ¿Qué tres preguntas secundarias ayudarían a responderla?
4. ¿Qué datos necesitaríamos?
5. ¿Qué variables serían indispensables?
6. ¿Dónde podríamos obtener esos datos?
7. ¿La fuente sería primaria, secundaria o terciaria?
8. ¿Qué problemas de calidad anticipamos?

R1 • Producto esperado

Al finalizar R1 el grupo debe demostrar que entiende el problema y posee una base de datos justificable para comenzar el proceso de minería.

Debe quedar publicado en Flask:

- Problema y contexto.

- 1 pregunta principal + mínimo 3 secundarias.

- Fuentes de datos clasificadas y justificadas.

- Dataset inicial.

- Diccionario de datos.

- Caracterización de registros y variables.

- Diagnóstico inicial de calidad.

- Limitaciones y consideraciones.

R1 no busca todavía encontrar el mejor modelo: busca construir una base sólida para descubrir conocimiento.