Universidad de Cundinamarca

Programa académico: Ingeniería de Sistemas y Computación
Espacio académico: Minería de Datos

INFORME TÉCNICO

Etapa 6 - Conocimiento Oculto

Aprendizaje supervisado, clustering y análisis de comentarios de YouTube con Orange Data Mining

Proyecto: Wildfire Data Mining (Análisis de incendios forestales) -- escalas globales, nacional (Colombia) y regional (Cundinamarca)

Integrantes

Laura Valentina Bautista Vargas
Sergio Luis Gómez Ramírez
Camila Parra Berrio
Sara Vargas Carreño

Docente: Edison Gustavo Cañón Varela

Fecha: 12 noviembre del 2026

1. YouTube: extracción y análisis de comentarios

Autora: Laura Bautista

1.1 Pregunta y objetivo de la sección

Propósito de análisis: ¿qué causas, responsables, emociones y expectativas expresan los usuarios sobre los incendios forestales en Colombia, y en qué coinciden o difieren con lo que muestran los datos del IDEAM (Etapas 2-5 de este proyecto)?

Esto complementa el análisis descriptivo y multidimensional de las etapas anteriores con la perspectiva de la opinión pública: de dónde cree la gente que vienen los incendios, a quién responsabiliza, y qué pide o espera -- información que el dataset del IDEAM no registra (la causa solo existe en 4.148 de 35.355 eventos, y no existe en absoluto para 2023-2024).

1.2 Datos usados y transformaciones

Selección de videos

Búsqueda con la YouTube Data API v3 (search.list, regionCode=CO, relevanceLanguage=es), con 8 consultas en español que cubren distintos ángulos del tema (causas, prevención, bomberos, cambio climático, IDEAM, emergencias por departamento, medio ambiente).

- incendios forestales Colombia
- causas incendios forestales Colombia
- prevención incendios forestales Colombia
- incendios forestales Colombia bomberos
- incendios forestales Colombia cambio climático
- incendios forestales Colombia IDEAM
- emergencia incendios forestales Colombia departamentos
- incendios forestales Colombia medio ambiente

Se encontraron 84 videos candidatos distintos. Criterio de selección (documentado por video en motivo_seleccion dentro de videos_consultados.csv): el título o la descripción debe mencionar explícitamente "Colombia"; al menos 15 comentarios reportados por la API; un solo video por canal, priorizando el de más comentarios, para cubrir fuentes distintas.

Canal	Video	Comentarios obtenidos
VANGUARDIA	Denuncian posible provocación de incendios en Jamundí	333
Julia Buenaventura	Colombia en llamas: incendios provocados por ???	136
Daniel Coronell	Incendios forestales en Tolima desatan cruce político	106
RED MÁS Noticias	Alerta en Tolima: piden evacuar un municipio	73
El Espectador	Grave incendio en Villa de Leyva	33
Noticias Caracol	¿Qué hay detrás de los incendios forestales en Colombia?	35
NTN24	Emergencia en Colombia: incendios en Villa de Leyva	28
Caracol Radio	Bomberos amenazados en Tolima	24

Total: 8 videos, 768 comentarios obtenidos (fecha de extracción: 2026-11-12). Ningún video tuvo los comentarios desactivados en esta búsqueda.

Restricciones encontradas

- La búsqueda (search.list) cuesta 100 unidades de cuota por consulta; con 8 consultas se gastaron 800 unidades solo en buscar candidatos (cuota diaria por defecto: 10.000 unidades).
- No se piden las respuestas anidadas a los comentarios (replies), solo los comentarios de primer nivel.
- El orden de relevancia que devuelve la API no es perfectamente estable entre llamadas.

Limpieza (youtube_limpiar.py)

Comentarios obtenidos (crudos): 768. Se descartaron, en este orden y sin solapamiento:

Motivo	Comentarios descartados
Vacíos	0
Solo emojis o símbolos	18
Duplicados exactos (texto idéntico)	0
Muy cortos (menos de 3 palabras)	32
En otro idioma (heurística de palabras funcionales)	15
Total descartado	65
Comentarios finales	703

texto_limpio: minúsculas, sin URLs ni menciones (@usuario), espacios repetidos colapsados. La columna texto que se publica también se redacta (correos, teléfonos y menciones se reemplazan por [correo]/[telefono]/[mencion]); no se detectaron correos ni teléfonos en este conjunto. Limitación: la redacción automática no detecta nombres propios de particulares escritos en prosa libre (requeriría NER); no se encontraron casos evidentes al revisar una muestra, pero no se puede garantizar al 100%.

No se publica ningún dato de autor (nombre, canal del autor, foto, id real del comentario): el JSON crudo de la API, que sí trae esos campos, queda en data/etapa6/youtube/raw/ e ignorado por git (nunca se sube).

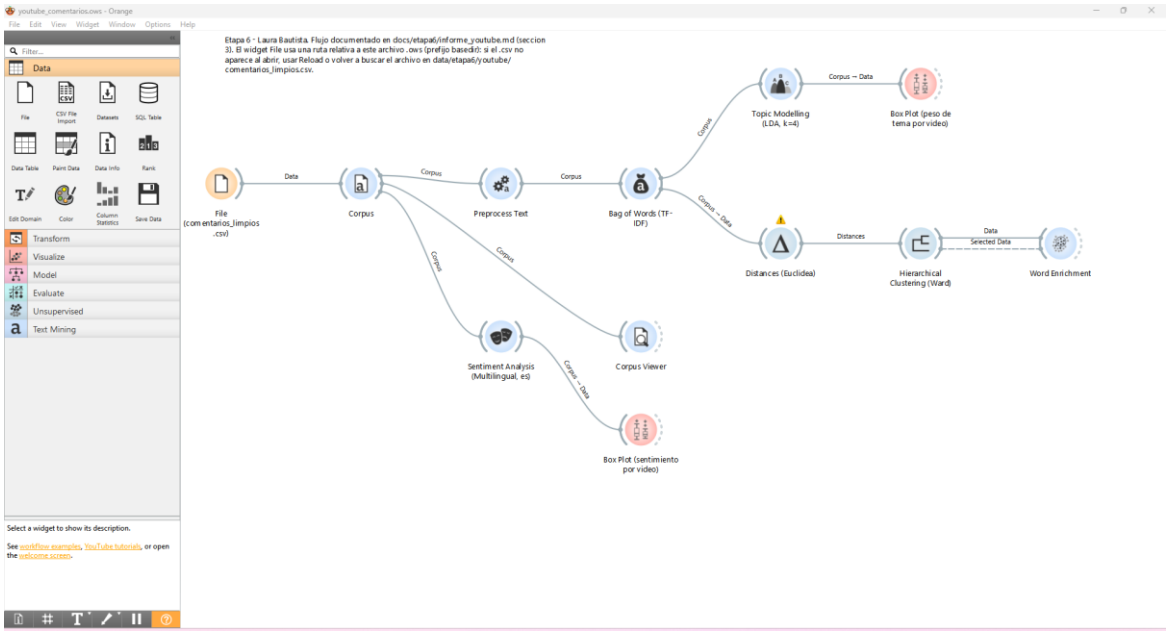
1.3 Flujo de Orange

Flujo guardado en orange/texto/youtube_comentarios.ows, generado con la API de esquemas de Orange y verificado abriéndolo en Orange Data Mining 3.40.0 (con el addon Orange3-Text).

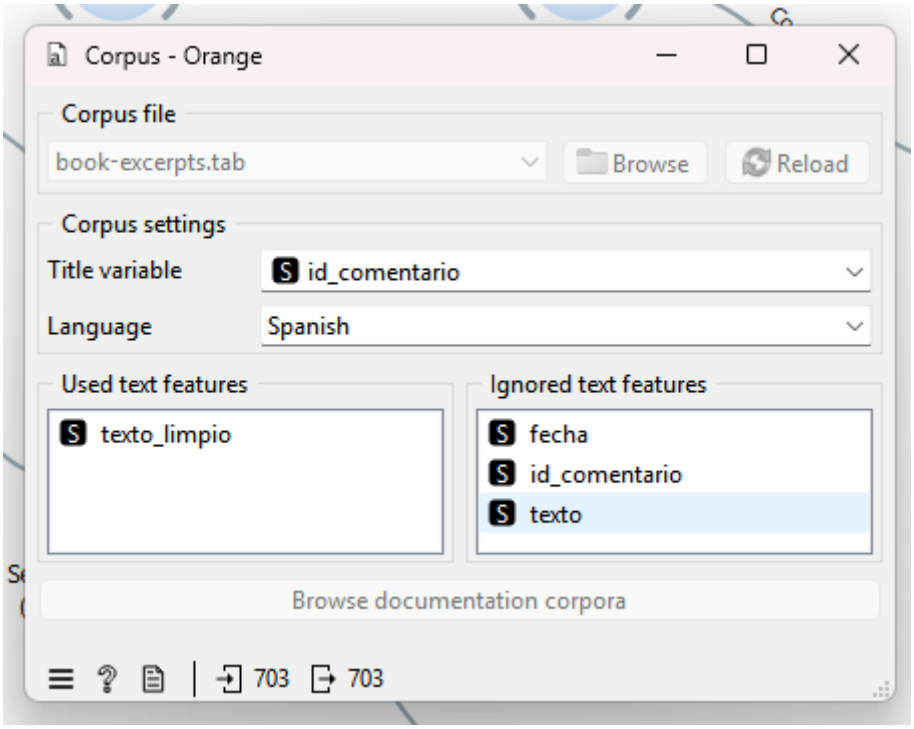
Widget	Conexión	Parámetros
File	(fuente)	Carga comentarios_limpios.csv con ruta relativa al .ows (prefijo basedir), para que abra en cualquier PC.
Corpus	File -> Corpus	Campo de texto: texto_limpio. Idioma: Spanish. 703 documentos.
Preprocess Text	Corpus -> Preprocess Text	Lowercase; Tokenización Regexp \w+; Normalización UDPipe Lemmatizer (es); Filtrado Stopwords (es) + frecuencia de documento 2%-90%. Vocabulario: ~70 términos.
Bag of Words	Preprocess -> Bag of Words	Term Frequency: Count. Document Frequency: IDF (TF-IDF clásico).
Topic Modelling	Bag of Words -> Topic Modelling	LDA, 4 temas (comparado 4-8 por coherencia c_v; k=4 mejor, 0,3281).
Distances	Bag of Words -> Distances	Métrica Euclidea (equivalente al enlace Ward).

Hierarchical Clustering	Distances -> HC	Enlace Ward. Sin partición útil (ver resultados).
Word Enrichment	HC -> Word Enrichment	Prueba hipergeométrica sobre los grupos pequeños que aísla el clustering.
Corpus Viewer	Corpus -> Corpus Viewer	Ejemplos anónimos y cortos de cada tema.
Sentiment Analysis	Corpus -> Sentiment Analysis	Multilingual Sentiment, idioma Spanish. Promedio general: -2,22.
Box Plot (x2)	Sentiment / Topic -> Box Plot	Comparación de sentimiento y de peso de tema, agrupados por video_id.

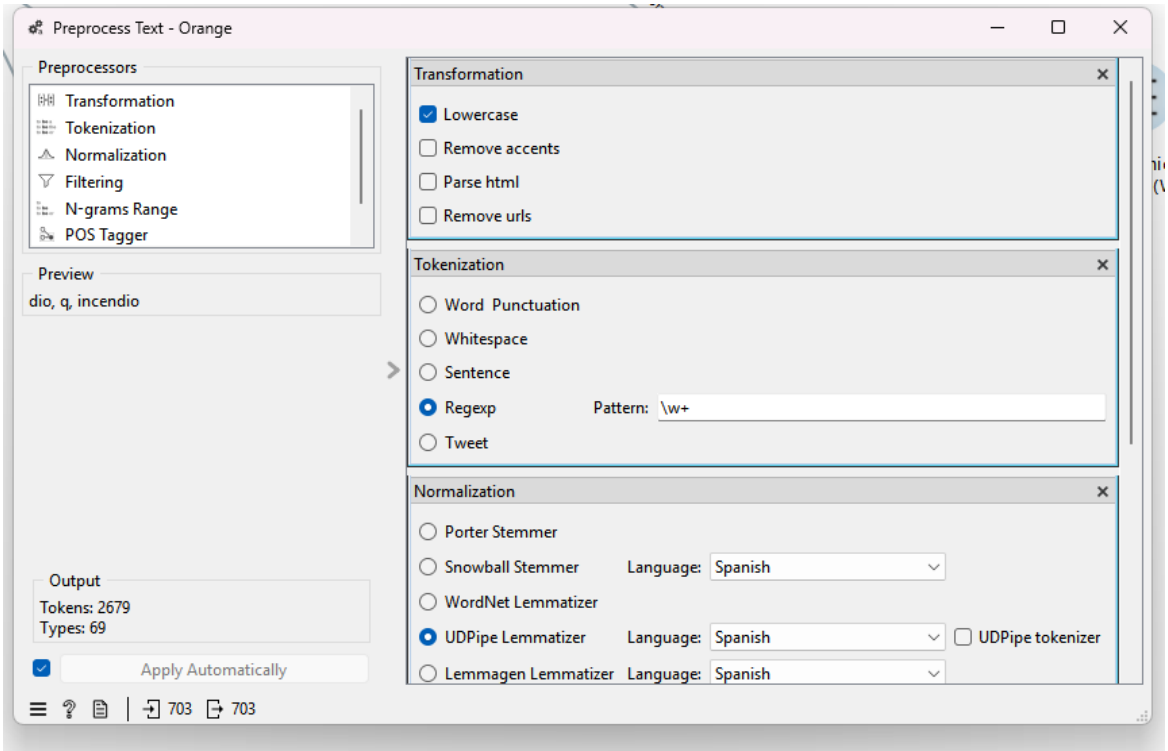
Flujo completo



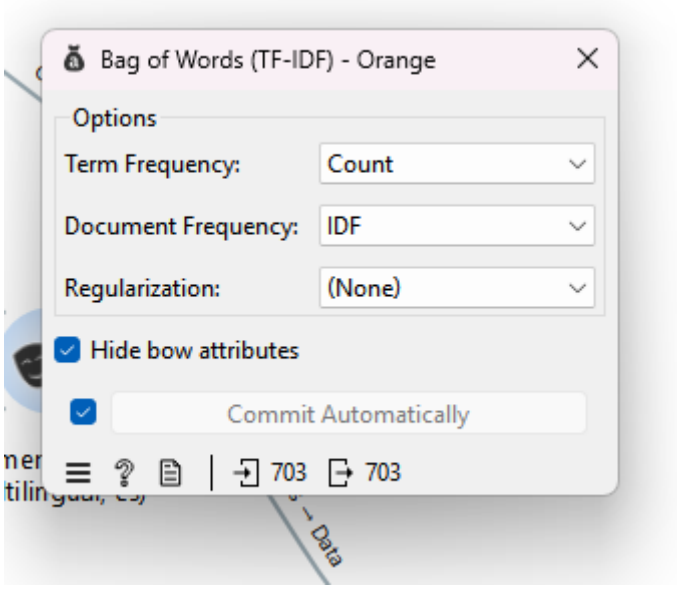
Configuración del widget Corpus: texto_limpio como única característica de texto usada, idioma Spanish, 703 documentos cargados desde comentarios_limpios.csv (vía el widget File).



Pipeline de preprocesamiento: transformación a minúsculas, tokenización Regexp (\w+), normalización con UDPipe Lemmatizer en español y filtrado (stopwords en español + frecuencia de documento). Resultado en la interfaz: 2.679 tokens en 69 tipos distintos sobre los 703 comentarios.



Vectorización Bag of Words: frecuencia de término por conteo (Count) ponderada por frecuencia inversa de documento (IDF), el esquema TF-IDF clásico usado como entrada para los temas y el clustering.

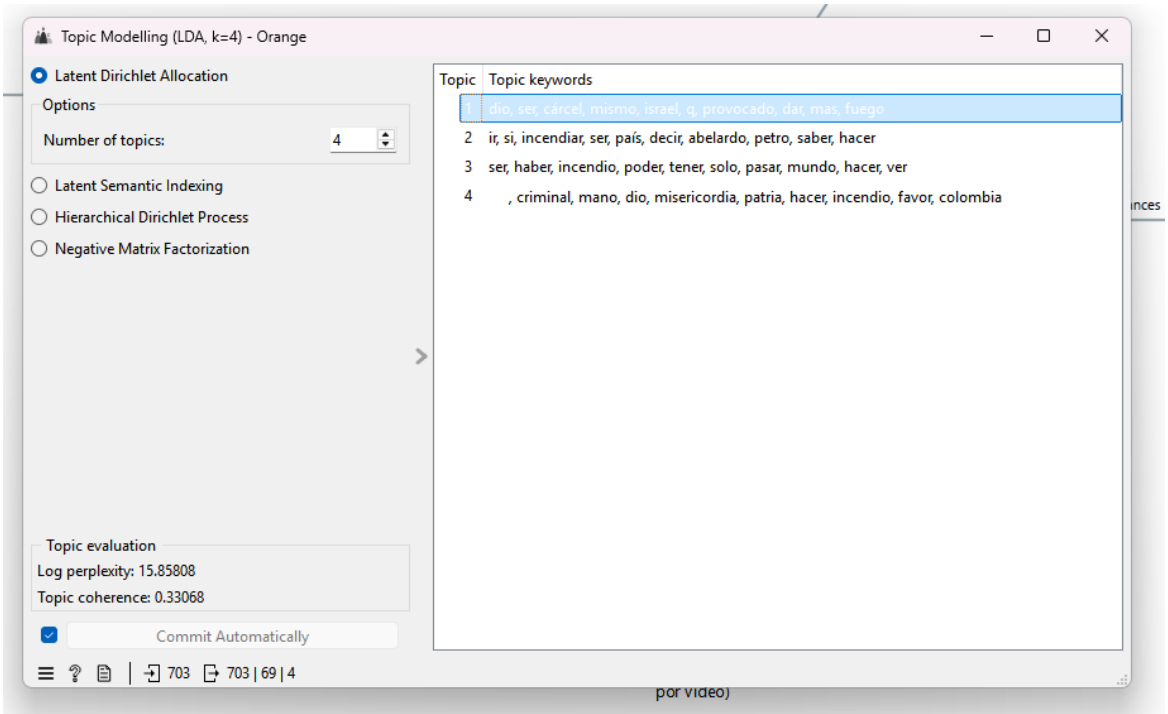


1.4 Resultados

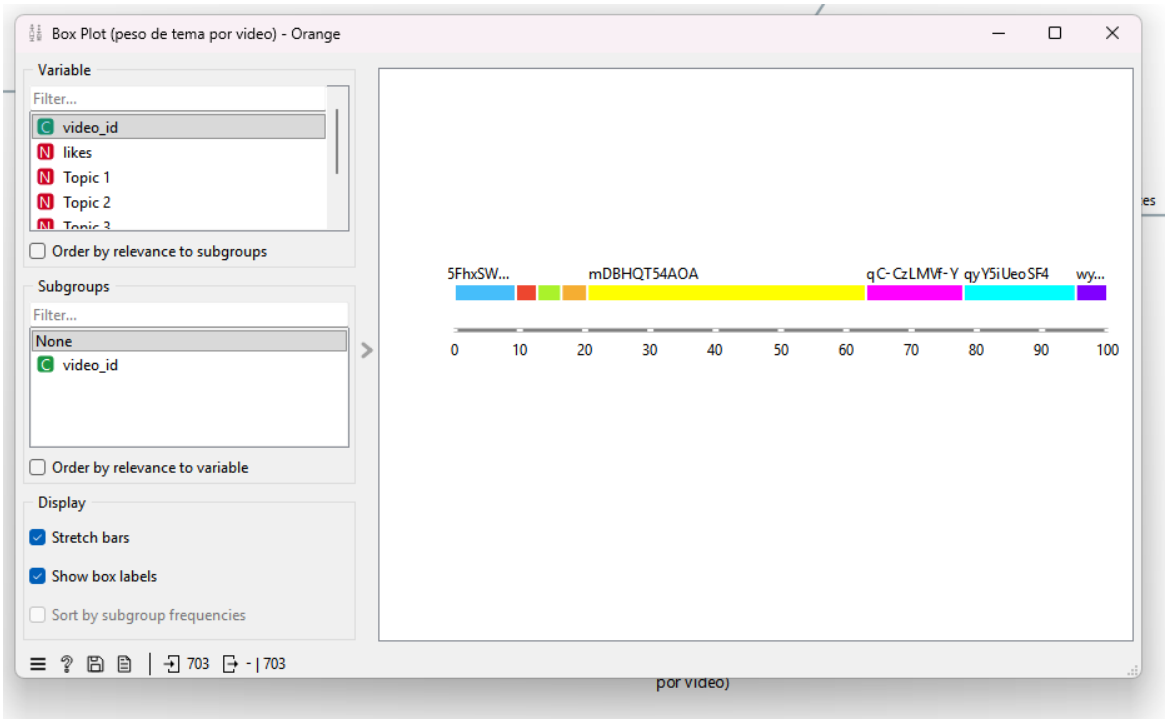
Temas (LDA, k=4, coherencia c_v=0,3281)

Tema	% (dominante)	Palabras representativas	Lectura
1	223 (31,7%)	dios, q, colombia, señor, favor, misericordia	Petición/ruego religioso: ayuda divina, lluvia, protección
2	186 (26,5%)	incendio, petro, incendiar, país, gobierno	Atribución política: responsabilidad del gobierno/presidente
3	130 (18,5%)	cárcel, querer, criminal, mano, daño	Acusación de intencionalidad: pedir captura/cárcel
4	164 (23,3%)	argentino, colombia, país, israel	Comparaciones geopolíticas (Argentina, Israel)

Los 4 temas obtenidos con LDA en la interfaz de Orange (coherencia 0,33; log-perplexity 15,86). Por la naturaleza estocástica de LDA, las palabras exactas de cada tema varían levemente entre ejecuciones, aunque los ejes temáticos (religioso, político, penal/geopolítico) se mantienen.

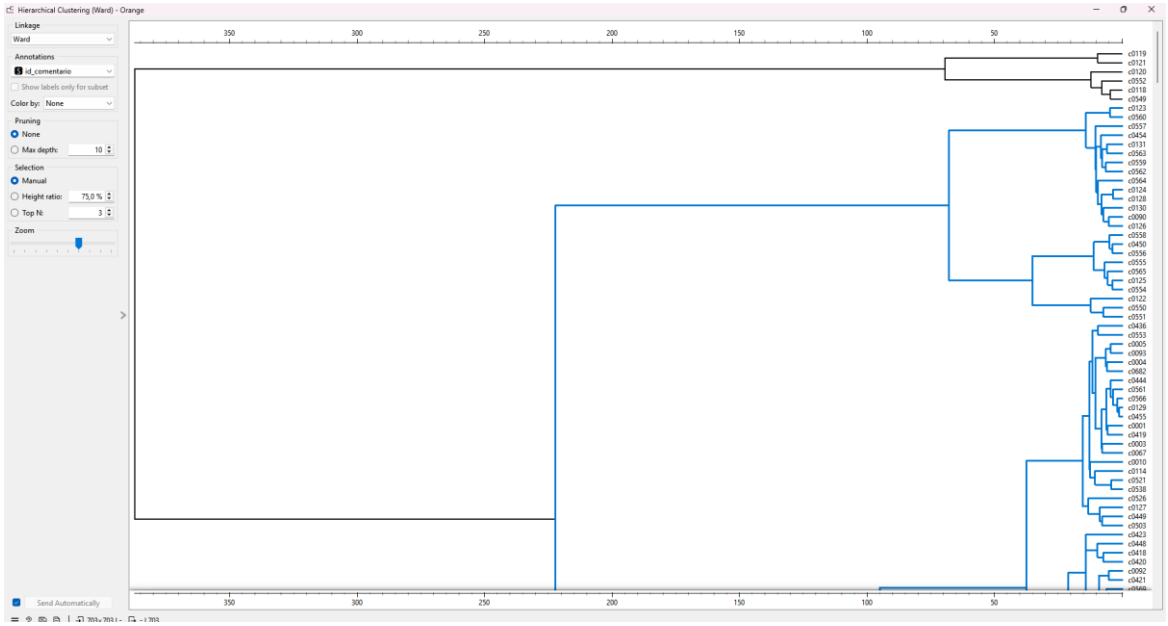


Distribución del peso de cada tema de LDA agrupada por video_id: permite comparar qué videos concentran más comentarios de cada tema (por ejemplo, el video de VANGUARDIA frente a los demás).



Clustering jerárquico (Ward): no se encontró una partición útil

Se compararon particiones de k=2 a k=8 sobre la misma matriz TF-IDF: el mejor silhouette (k=2, 0,70) solo aísla 3 comentarios atípicos del resto; con k=4 o k=5 vuelve a aislar grupos de 3-16 comentarios dejando ~97% en un solo grupo. Es un resultado real, no un error de ejecución: indica que este corpus no tiene subgrupos bien separados en el espacio de palabras.



Sentiment Analysis (Multilingual Sentiment, es)

Promedio general: -2,22 (escala del diccionario; negativo predomina). Por video:

Video (canal)	Comentarios	Sentimiento promedio
RED MÁS Noticias (Alerta Tolima)	66	+5,66
Julia Buenaventura (Colombia en llamas)	121	+1,24
NTN24 (Villa de Leyva emergencia)	26	+0,08
Caracol Radio (bomberos amenazados)	23	-0,69
Daniel Coronell (Tolima cruce político)	105	-0,72
El Espectador (Villa de Leyva)	28	-1,25
Noticias Caracol (¿qué hay detrás?)	34	-4,64
VANGUARDIA (Jamundí, denuncia provocación)	300	-6,01

1.5 Interpretación y qué aporta frente al problema del proyecto

Los 4 temas identificados muestran que la conversación pública sobre incendios forestales en Colombia se organiza, sobre todo, alrededor de dos ejes que no están en los datos del IDEAM: la atribución de responsabilidad (política y de intencionalidad delictiva) y la reacción emocional/religiosa. Contraste verificable: la causa del incendio solo está registrada en 4.148 de 35.355 eventos (11,7%) y no se registra en absoluto para 2023-2024; sin embargo, casi el 19% de los comentarios (Tema 3, 130 de 703) gira en torno a la sospecha de que los incendios son provocados.

El análisis de sentimiento aporta algo que ni el IDEAM ni el conteo de palabras muestran por sí solos: el tono varía fuertemente según el video (de +5,66 a -6,01), no solo según el tema. El enfoque editorial de cada medio (acusatorio vs. centrado en la emergencia humana) influye en el tono de los comentarios tanto como el evento mismo.

El hallazgo de que el clustering jerárquico no separa el corpus en grupos también es información útil: indica que, en estos 8 videos, no hay subgrupos de comentaristas con vocabulario marcadamente distinto; los mismos comentarios mezclan varios tonos y temas a la vez.

1.6 Limitaciones y qué es hipótesis

- Los comentarios son opiniones de quienes comentaron en 8 videos puntuales, no una muestra representativa. Un solo video (VANGUARDIA, 300 de 703, 42,7%) concentra casi la mitad de la muestra.
- La heurística de detección de idioma y la redacción de datos personales son reglas simples (no usan modelos de lenguaje ni NER).
- La atribución de causa a nivel de comentario es una percepción, no un hecho verificado.
- Los 4 temas de LDA tienen coherencia moderada (c_v ~0,33); la asignación de un comentario a 'su' tema dominante es una simplificación.
- El clustering jerárquico (Ward) no produjo grupos balanceados en ningún k probado (2 a 8).
- El análisis de sentimiento usa un diccionario de palabras (no entiende sarcasmo ni el contexto figurado de expresiones como 'misericordia' en medio de una tragedia).

1.7 Cómo reproducirlo

Desde la raíz del repositorio, con un archivo .env que tenga YOUTUBE_API_KEY=tu_clave:

python scripts/etapa6/youtube_extraer.py

python scripts/etapa6/youtube_limpiar.py

Luego abrir orange/texto/youtube_comentarios.ows en Orange Data Mining 3.40.0 (con el addon Orange3-Text instalado): el flujo ya trae los 12 widgets conectados y sus parámetros cargados; solo falta marcar texto_limpio + idioma Spanish en Corpus y la variable de agrupación (video_id) en los dos Box Plot, y ejecutar.

1.8 Resumen para las conclusiones integradas

- Hallazgo: de 768 comentarios en 8 videos, 703 quedaron útiles tras la limpieza (91,5%), pero un solo video (VANGUARDIA) concentra el 42,7% de la muestra. Evidencia, no hipótesis.
- Hallazgo: los 4 temas de LDA muestran que casi el 45% de los comentarios (Temas 2 y 3) giran en torno a atribuir el incendio a causa intencional o política, mientras el IDEAM solo documenta la causa en el 11,7% de los eventos. Evidencia de lo que se comenta; la atribución de intencionalidad en sí misma es percepción, no hecho verificado.
- Hallazgo: el sentimiento promedio varía fuertemente por video (+5,66 a -6,01), ligado al enfoque editorial de cada cobertura más que al tema. Evidencia, con la salvedad de que el diccionario de sentimiento es impreciso con sarcasmo y lenguaje figurado.
- Hallazgo: el clustering jerárquico no encontró una partición balanceada en ningún k de 2 a 8. Evidencia (resultado real del algoritmo, no hipótesis sobre los comentaristas).

Limitación principal: opiniones de quienes comentaron en 8 videos puntuales (uno de ellos con casi la mitad de los comentarios), no de toda la población.

2. Aprendizaje supervisado

Autora: Sara Vargas

2.1 Pregunta y objetivo

Pregunta de predicción: dado un incendio de cobertura vegetal reportado, con la información disponible al momento del reporte (año, mes, departamento y hoja de origen del registro), ¿puede predecirse si será **grande**, es decir, de más de 100 hectáreas?

Tipo de problema: clasificación binaria. La variable objetivo es una categoría (`Grande` / `No grande`). Se eligió clasificación y no regresión por dos razones: el área de los incendios es muy asimétrica (mediana de 2 ha y promedio de 46,6 ha en todo el conjunto), de modo que predecir el valor exacto en hectáreas daría un error dominado por unos pocos eventos extremos; y lo que importa para la gestión es anticipar los eventos extensos, que son la minoría. El umbral de 100 ha es el mismo que se usó en las vistas de la Etapa 5 ("incendio grande").

Objetivo de la sección: implementar tres modelos supervisados distintos para esta pregunta, evaluarlos en las mismas condiciones, compararlos, elegir uno y describir qué conocimiento aporta y cuáles son sus límites.

2.2 Datos y transformaciones

Origen: `data/processed/incendios_ideam_tratado_2010_2024.csv`, el CSV tratado en la Etapa 2 (35.355 eventos de la BD-ICV del IDEAM, 2010-2024). La preparación se hace con `scripts/etapa6/preparar_supervisado.py`, que escribe `data/etapa6/supervisado/incendios_supervisado.tab` (formato nativo de Orange, con la clase y el identificador ya marcados).

Paso	Eventos	Motivo
CSV tratado	35.355	Punto de partida
Sin área informada (se descartan)	−775	Sin el área no se puede saber si el incendio fue grande; el área nula no se convierte en 0
Sin año (se descarta)	−1	El año es una predictora
Archivo para Orange	**34.579**	

Variable objetivo `clase`: `Grande` si el área total supera 100 ha. Resultado: **1.674 eventos grandes (4,84 %)** y 32.905 no grandes (95,16 %).

Predictoras (4): `anio` (numérica), `mes` (categórica; "Sin mes" para los nulos, 13 categorías), `departamento` (categórica; "Sin departamento" para los nulos, 34 categorías) y `hoja_origen` (categórica, 5 categorías: la hoja del libro del IDEAM de donde viene el registro). El identificador `id_evento` va como metadato y no entra al modelo.

Variables excluidas y por qué. Se evitó usar información que no estaría disponible al predecir y que contiene la respuesta:

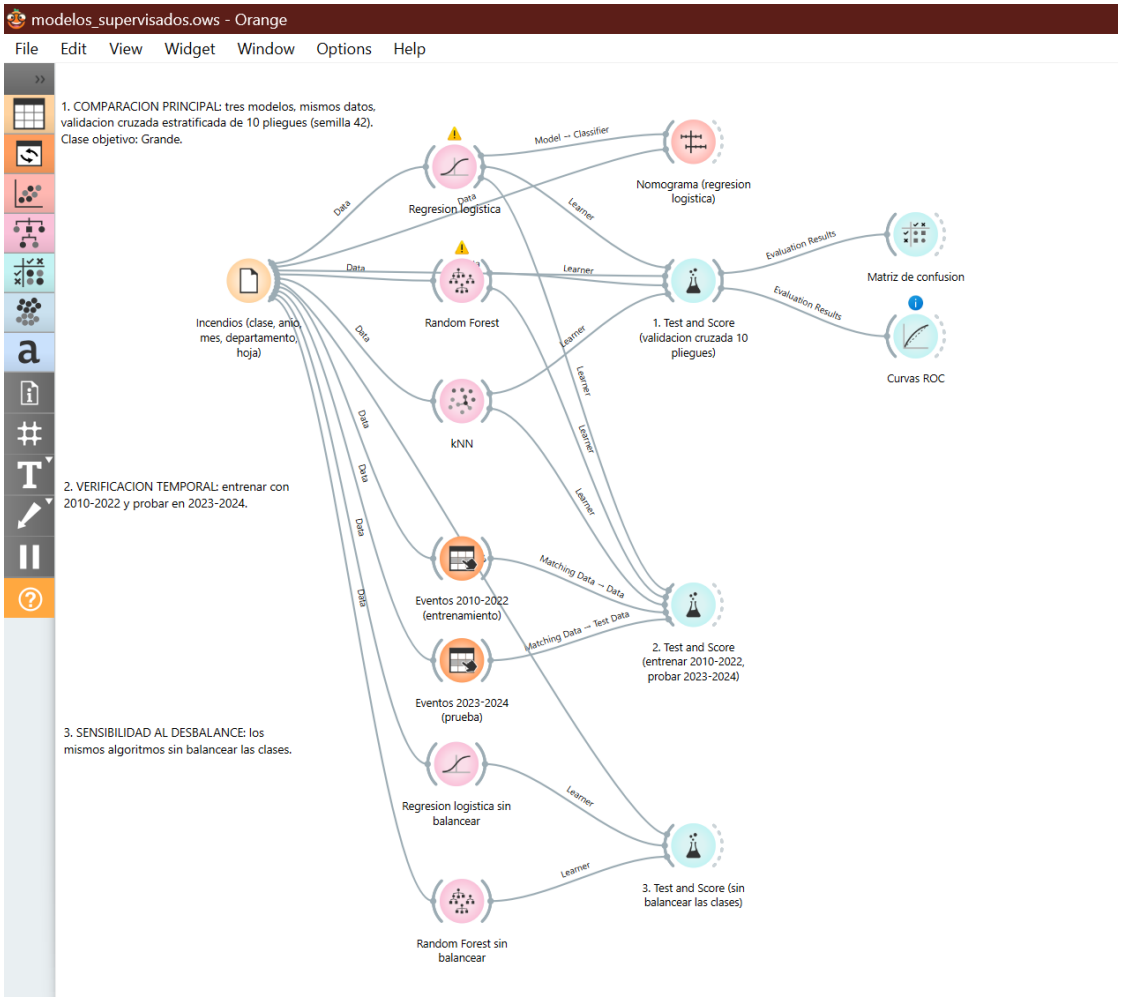
Variables	Motivo de la exclusión
AREA_*_HA, AREA_TOTAL_HA, AREA_TOTAL_HA_NUM, AREA_*_NUM	Expresan el área: contienen la respuesta (fuga de información)
AREA_TOTAL_ATIPICO	Se deriva del área: los 1.674 eventos grandes están todos marcados
COB_*, COB_*_NUM	Hectáreas por tipo de cobertura: expresan el área (fuga de información)
CAUSA_*	Se conoce después del evento y falta en la mayoría de los registros
LATITUD_DEC, LONGITUD_DEC, ELEVACION_MSNM_NUM	Nulas en el 97 % de los eventos con área
AREA_PROTEGIDA_NACIONAL	Nula en el 98 % de los eventos con área y con respuestas inconsistentes
MUNICIPIO_NORM	Más de mil categorías para el tamaño de la muestra
ENTIDAD_REPORTA	Solo existe en la hoja 2024

Desbalance de clases. Solo el 4,84 % de los eventos es grande. Un modelo que respondiera siempre "No grande" tendría una exactitud (accuracy) de **95,16 %** sin detectar ningún incendio grande. Por eso la exactitud no sirve como criterio: se usan AUC, precisión, recall y F1 de la clase `Grande`, además de la matriz de confusión.

2.3 Flujo de Orange

Archivo: `orange/supervisado/modelos_supervisados.ows` (Orange 3.40.0). Se genera con `scripts/etapa6/generar_flujo_supervisado.py` y los datos se cargan con una ruta relativa (`../../data/etapa6/supervisado/incendios_supervisado.tab`).

Figura 2.1. Flujo completo en Orange (`modelos_supervisados.ows`). A la izquierda, el widget File carga los 34.579 eventos y alimenta a los tres modelos (regresión logística, Random Forest y kNN). El bloque 1 (arriba) los evalúa con validación cruzada estratificada de 10 pliegues en `Test and Score`, de donde salen la matriz de confusión y las curvas ROC; el nomograma se conecta al modelo de regresión logística. El bloque 2 (centro) usa dos widgets `Select Rows` (año hasta 2022 y año desde 2023) para entrenar con el pasado y probar con datos posteriores. El bloque 3 (abajo) repite la regresión logística y el Random Forest sin balancear las clases. Los triángulos amarillos sobre los dos modelos balanceados son el aviso de Orange de que se activó "Balance class distribution", lo cual es intencional.



Widget	Conexión (de → a)	Parámetros
File	Data → los tres modelos, Test and Score 1 y 3, Nomogram y los dos Select Rows	`incendios_supervisado.tab`; `clase` como variable objetivo; `id_evento` como metadato
Logistic Regression	Data ← File; Learner → Test and Score 1 y 2; Model → Nomogram	Regularización Ridge (L2), C = 1, *Balance class distribution* activado
Random Forest	Data ← File; Learner → Test and Score 1 y 2	300 árboles, no dividir subconjuntos menores de 20, *Balance class distribution* y *Replicable training* activados; el resto por defecto
kNN	Data ← File; Learner → Test and Score 1 y 2	25 vecinos, métrica euclidiana, peso uniforme (no admite balanceo de clases)

Widget	Conexión (de → a)	Parámetros
Test and Score 1	Learner ← los tres modelos; Data ← File; Evaluation Results → Confusion Matrix y ROC Analysis	Validación cruzada estratificada de 10 pliegues (semilla 42); clase objetivo `Grande`
Confusion Matrix	Evaluation Results ← Test and Score 1	Se examina un modelo a la vez
ROC Analysis	Evaluation Results ← Test and Score 1	Clase objetivo `Grande`
Nomogram	Classifier ← Logistic Regression (Model); Data ← File	Clase objetivo `Grande`
Select Rows (2)	Data ← File; Matching Data → Test and Score 2	`anio` es como máximo 2022 (entrenamiento) y `anio` es al menos 2023 (prueba)
Test and Score 2	Learner ← los tres modelos; Data y Test Data ← Select Rows	*Test on test data*
Logistic Regression y **Random Forest** sin balancear	Data ← File; Learner → Test and Score 3	Mismos parámetros, con *Balance class distribution* desactivado
Test and Score 3	Learner ← los dos modelos sin balancear; Data ← File	Validación cruzada estratificada de 10 pliegues (semilla 42)

Los tres modelos reciben los mismos datos y se evalúan con la misma partición, así que la comparación es consistente. Orange aplica a cada modelo su preprocesamiento por defecto (codificación de las categóricas, imputación de nulos).

2.4 Resultados

Configuración de la comparación principal: validación cruzada estratificada de 10 pliegues con semilla 42. Clase de interés: `Grande`.

2.4.1 Comparación de los tres modelos

Modelo	AUC	Exactitud	F1	Precisión	Recall
Regresión logística	0,772	0,717	0,192	0,111	0,694
Random Forest	0,774	0,790	0,223	0,136	0,622
kNN	0,730	0,951	0,024	0,318	0,013

Matriz de confusión (clase `Grande`; filas = real, columnas = predicho):

Modelo	Detectados (VP)	No detectados (FN)	Falsas alarmas (FP)	No grandes bien clasificados (VN)
Regresión logística	1.161	513	9.274	23.631
Random Forest	1.041	633	6.623	26.282
kNN	21	1.653	45	32.860

Figura 2.2. `Test and Score` con validación cruzada estratificada de 10 pliegues y la clase objetivo `Grande` (arriba a la derecha). Cada fila es un modelo y las columnas son AUC, CA (exactitud), F1, precisión, recall y MCC. El AUC de la regresión logística y del Random Forest es casi igual (0,772 y 0,774); el kNN tiene exactitud alta (0,951) pero recall de 0,013; la regresión logística tiene el mayor recall (0,694). La tabla inferior compara los modelos por AUC: la probabilidad de que el Random Forest supere a la regresión logística es de solo 0,601, es decir, no hay una diferencia clara entre ambos.

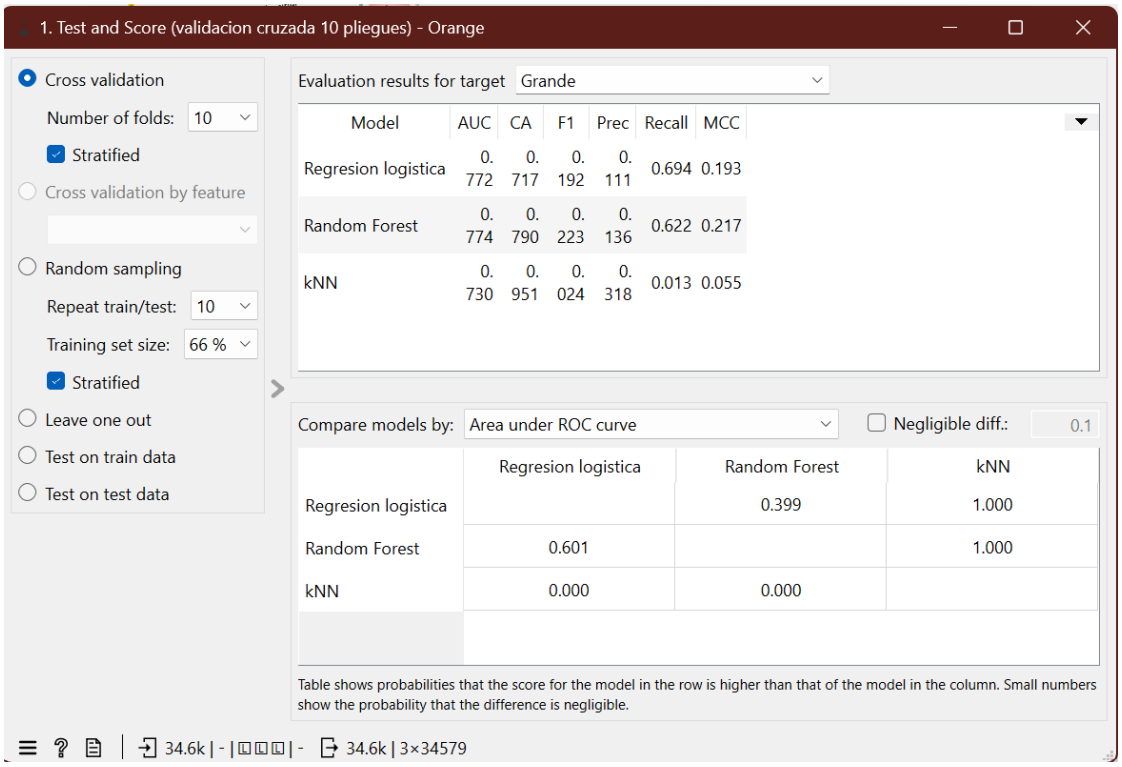


Figura 2.3. Matriz de confusión de la regresión logística (modelo elegido) con la opción "Number of instances". De los 1.674 incendios grandes reales, 1.161 se detectan y 513 no (recall de 0,694); de los 32.905 no grandes, 9.274 se marcan como grandes (falsas alarmas) y 23.631 se clasifican bien. El modelo señala 10.435 eventos como grandes y solo 1.161 lo son (precisión de 0,111): por cada incendio grande detectado hay unas 8 falsas alarmas.

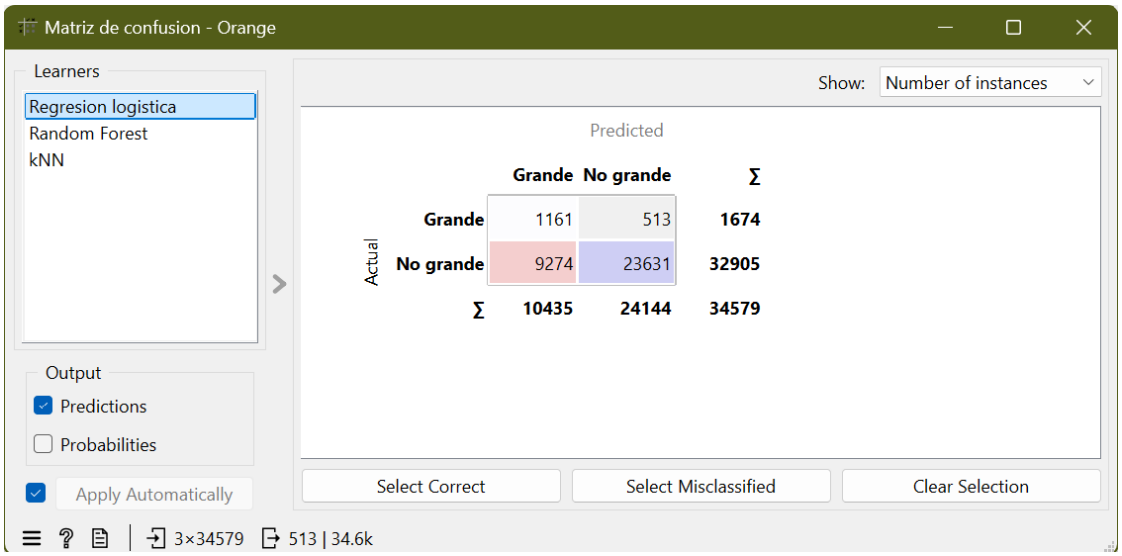
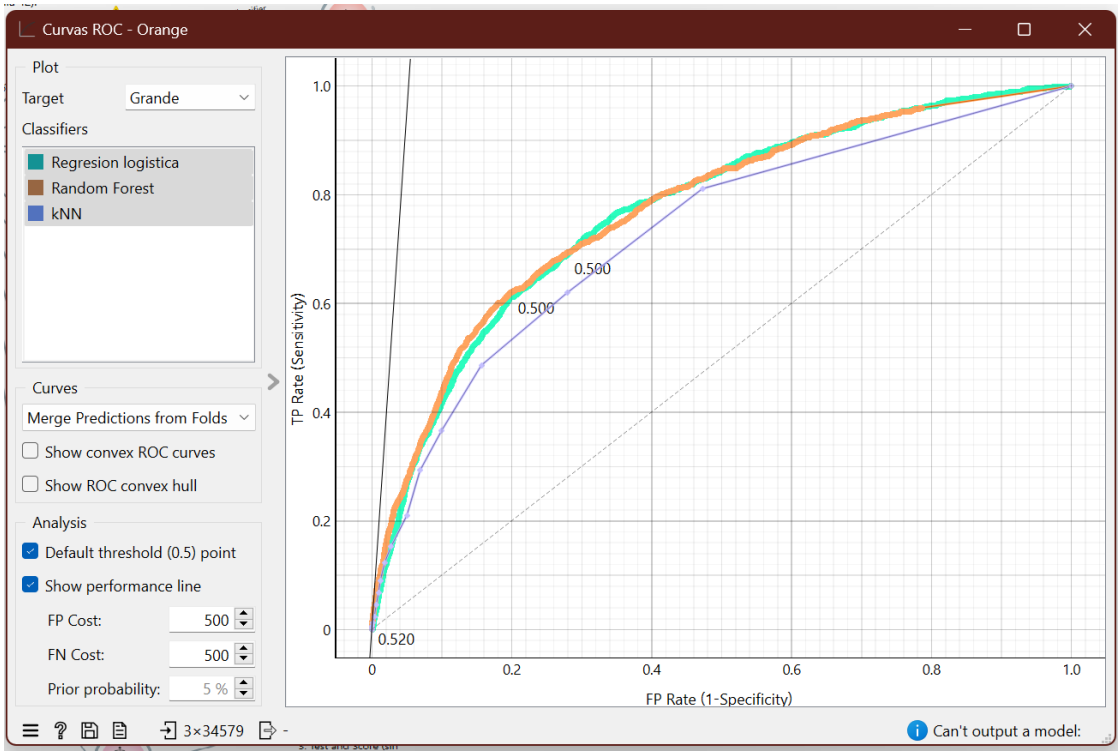


Figura 2.4. Curvas ROC de los tres modelos para la clase Grande, con las predicciones de todos los pliegues. La regresión logística (verde azulado) y el Random Forest (naranja) casi se superponen y quedan claramente por encima de la diagonal punteada (azar); la curva del kNN (violeta) queda por debajo en casi todo el recorrido. Los puntos marcados "0,500" son el umbral de decisión por defecto: la regresión logística (recall de 0,694) queda con cerca de 28 % de falsas alarmas entre los eventos no grandes (9.274 de 32.905) y el Random Forest (recall de 0,622) con cerca de 20 % (6.623 de 32.905); el punto del kNN queda pegado al origen.



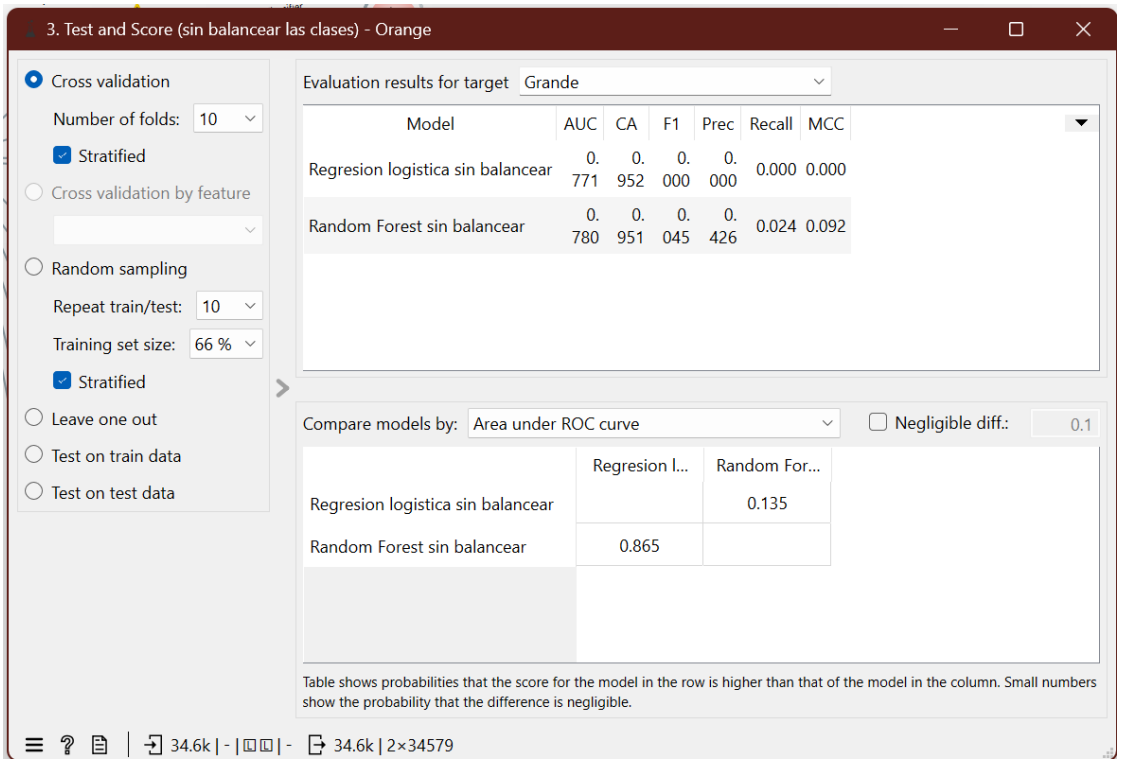
Cómo leer el desbalance. La exactitud de kNN (0,951) parece excelente y casi coincide con la línea base (0,9516), pero solo detecta 21 de los 1.674 incendios grandes (recall de 1,3 %). Los dos modelos que balancean las clases tienen una exactitud menor (0,72 y 0,79) y, sin embargo, detectan entre el 62 % y el 69 % de los incendios grandes: aceptan más falsas alarmas a cambio de no dejar pasar los eventos extensos. Con el 4,84 % de positivos, la precisión es baja en todos los casos: la regresión logística acierta en 1 de cada 9 alertas (precisión de 0,111), unas 8 falsas alarmas por incendio grande detectado; el Random Forest, unas 6.

2.4.2 Sensibilidad al desbalance: los mismos algoritmos sin balancear las clases

Modelo	AUC	Exactitud	F1	Precisión	Recall
Regresión logística sin balancear	0,771	0,952	0,000	0,000	0,000
Random Forest sin balancear	0,780	0,951	0,045	0,426	0,024

Sin balancear, la regresión logística no detecta ningún incendio grande (0 de 1.674) y su exactitud de 0,952 coincide con la de la línea base. Su AUC casi no cambia (0,771 frente a 0,772): el modelo **ordena** igual de bien los eventos, pero con el umbral por defecto nunca los clasifica como grandes. Esto muestra que el desbalance afecta a las métricas de decisión (recall, F1, matriz de confusión), no a la capacidad de ordenar por riesgo.

Figura 2.5. `Test and Score` 3: los mismos algoritmos sin balancear las clases, con la misma validación. La regresión logística tiene AUC 0,771 y exactitud 0,952, pero F1, precisión y recall de 0,000: nunca clasifica un evento como grande. El Random Forest sin balancear tiene AUC 0,780 y recall de 0,024. La exactitud de 0,95 es igual a la de la línea base, por eso no sirve como criterio en este problema.



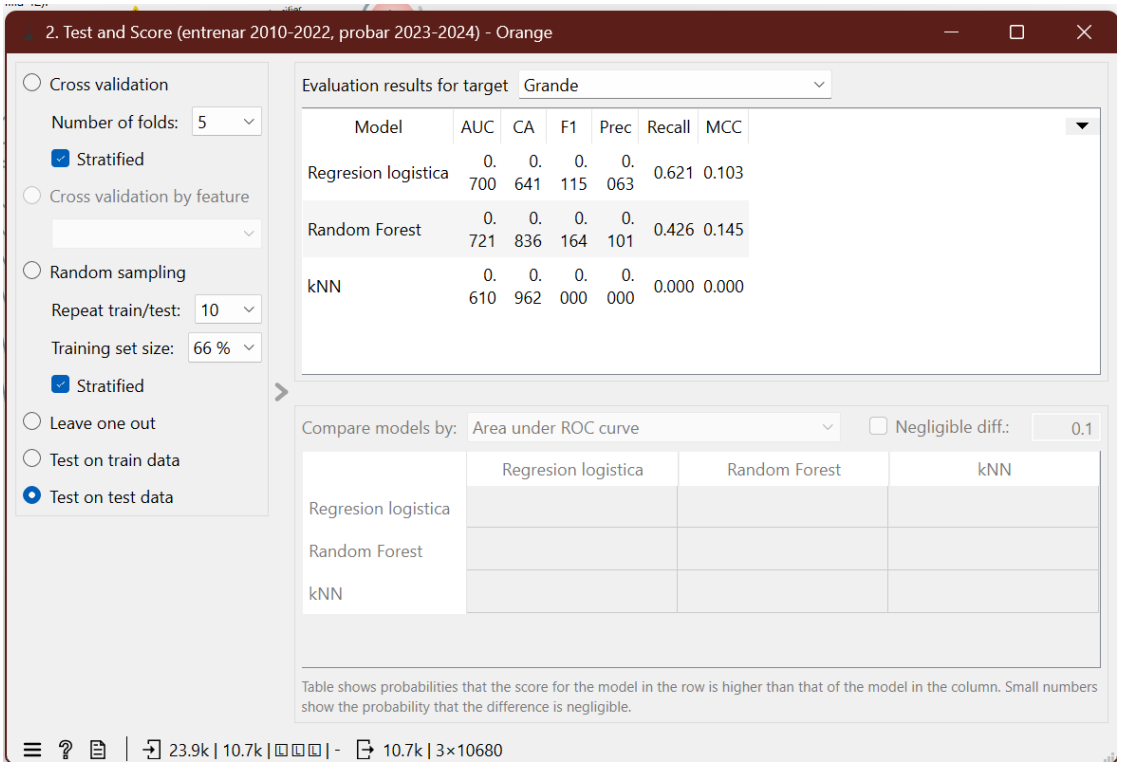
2.4.3 Verificación temporal: entrenar con 2010-2022 y probar en 2023-2024

Entrenamiento: 23.899 eventos (1.273 grandes). Prueba: 10.680 eventos (401 grandes, 3,75 %).

Modelo	AUC	Exactitud	F1	Precisión	Recall
Regresión logística	0,700	0,641	0,115	0,063	0,621
Random Forest	0,721	0,836	0,164	0,101	0,426
kNN	0,610	0,962	0,000	0,000	0,000

Con datos futuros el desempeño baja en los tres modelos (el AUC de la regresión logística cae de 0,772 a 0,700 y el del Random Forest de 0,774 a 0,721), lo que indica que parte de lo aprendido en la validación cruzada depende del periodo: el reporte cambia entre hojas de origen y años.

Figura 2.6. `Test and Score` 2 con la opción "Test on test data": entrenamiento con 23,9 mil eventos de 2010-2022 y prueba con 10,7 mil de 2023-2024 (indicadores de la barra inferior). Con datos posteriores el AUC baja a 0,700 (regresión logística) y 0,721 (Random Forest); el recall del Random Forest cae a 0,426 y el kNN no detecta ningún incendio grande.



2.4.4 Qué variables pesan

Tasa observada de incendios grandes (sobre eventos con área; el promedio general es 4,84 %):

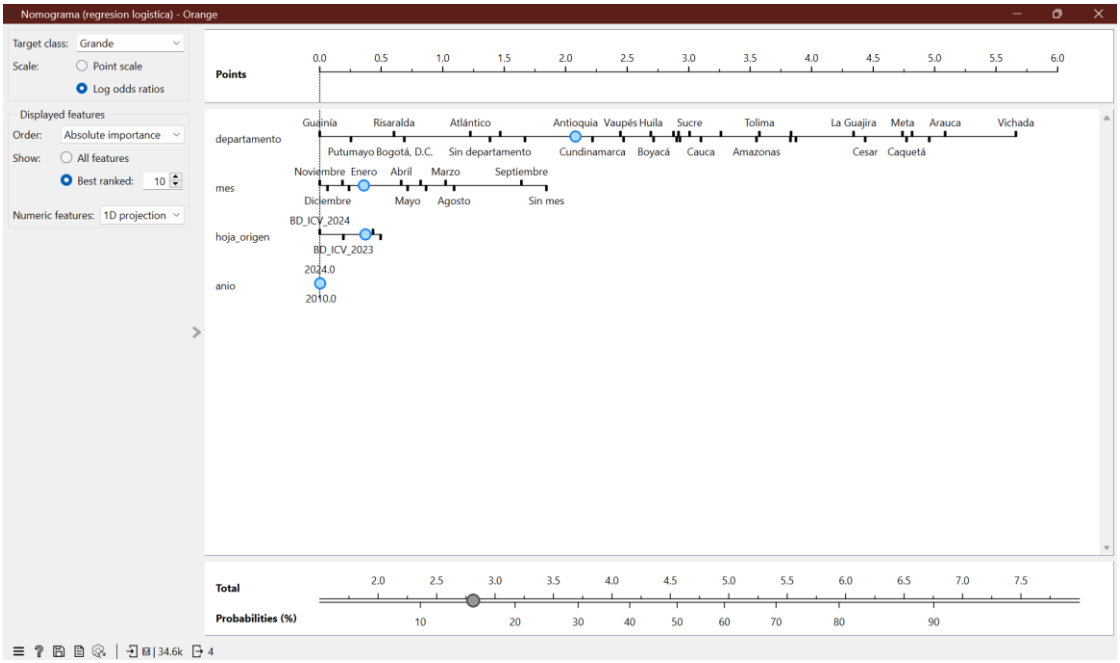
Departamento	Grandes	Eventos	Tasa
Vichada	93	360	25,8 %
Arauca	92	437	21,1 %
Casanare	235	1.485	15,8 %
Meta	194	1.358	14,3 %
Caquetá	49	348	14,1 %
Bogotá, D.C.	1	367	0,3 %
Risaralda	1	405	0,2 %

(Solo se listan departamentos con al menos 100 eventos.) Por mes, marzo (7,0 %), febrero (6,6 %) y septiembre (5,9 %) concentran la mayor proporción de incendios grandes, frente a junio, julio y noviembre (1,9 %). Por hoja de origen, 2022 (8,8 %) y 2021 (7,4 %) superan a 2024 (3,6 %).

En la regresión logística (balanceada) los coeficientes de mayor tamaño son los de departamento. Valores en logaritmo de las razones de probabilidades para la clase `Grande` (positivo = más probabilidad de ser grande, con el resto de variables iguales): Vichada (+2,71), Arauca (+2,13), Casanare (+1,86), Caquetá (+1,82) y Meta (+1,78); y, en el sentido contrario, Guainía (−2,95), Putumayo (−2,70), Risaralda (−2,35) y Bogotá, D.C. (−2,27). Entre los meses, una vez descontado el departamento, el más alto es septiembre (+0,90), seguido de agosto (+0,35) y marzo (+0,29), y los más bajos noviembre (−0,74), diciembre (−0,67), julio (−0,55) y junio (−0,50). El año (−0,0002 por

año) y la hoja de origen (entre −0,32 y +0,18) casi no aportan. Orange calcula los coeficientes respecto a la segunda clase del archivo (`No grande`); aquí se muestran con el signo invertido para leerlos respecto a `Grande`, que es como los presenta el widget Nomogram con la clase objetivo `Grande`.

Figura 2.7. Nomograma de la regresión logística para la clase `Grande`, con la escala en logaritmo de las razones de probabilidades. Las variables están ordenadas por importancia: el departamento abarca el rango más amplio (desde Guainía, el más bajo, hasta Vichada, el más alto, unas 5,7 unidades), seguido del mes (septiembre y "Sin mes" arriba; noviembre y diciembre abajo), la hoja de origen (rango pequeño) y el año (casi nulo). El punto azul marca el valor seleccionado en cada variable y la barra inferior convierte la suma de puntos en una probabilidad.



2.5 Modelo seleccionado

Se selecciona la regresión logística (con clases balanceadas). Razones:

- **Desempeño:** su AUC (0,772) es prácticamente igual al del Random Forest (0,774); la diferencia de 0,002 no es clara: la comparación por AUC de Orange (figura 2.2) da solo 0,601 de probabilidad de que el Random Forest supere a la regresión logística. Es el modelo con mayor recall (0,694): detecta 1.161 de los 1.674 incendios grandes, 120 más que el Random Forest.
- **Errores que comete:** deja pasar el 31 % de los incendios grandes (513 falsos negativos) y genera 9.274 falsas alarmas. En este problema un falso negativo es más costoso que una falsa alarma, porque un incendio extenso que no se anticipa es el caso que más daño causa; por eso se privilegia el recall.
- **Interpretación:** sus coeficientes y el nomograma dicen qué departamentos, meses y hojas aumentan o reducen la probabilidad de un incendio grande; el Random Forest no ofrece esa lectura directa.
- **Utilidad:** sirve para priorizar la vigilancia: ordenar los departamentos y meses por riesgo y reforzar el seguimiento donde la probabilidad es mayor.

Por qué no el Random Forest: tiene mejor F1 (0,223 frente a 0,192), mayor precisión (0,136 frente a 0,111), menos falsas alarmas (6.623 frente a 9.274) y se degrada menos con datos futuros (AUC de 0,721 frente a 0,700). Sería la mejor opción si el costo de una falsa alarma fuera alto. Aunque la

importancia de variables del Random Forest también pone primero al departamento (51,7 %), le asigna 24,0 % al año, que en la regresión logística casi no pesa (−0,0002 por año): las importancias de los bosques de árboles suelen favorecer a las variables numéricas, por lo que se interpretan con más cautela que los coeficientes de la regresión logística. **Por qué no kNN:** detecta solo el 1,3 % de los incendios grandes y no admite balanceo de clases.

Qué conocimiento aporta: frente al conocimiento evidente de las etapas anteriores (donde se contaban eventos y hectáreas por región), el modelo cuantifica que **la probabilidad de que un incendio sea grande depende sobre todo del departamento**, con las tasas más altas en los llanos orientales (Vichada, Arauca, Casanare y Meta) y en Caquetá, y que dentro del año se concentra en febrero, marzo y septiembre (tasas observadas); al descontar el departamento, el mes con más peso es septiembre.

2.6 Limitaciones y qué es hipótesis

- **Pocas predictoras.** Solo hay cuatro variables disponibles de forma confiable; no hay clima, vegetación ni condiciones del terreno. Un AUC de 0,77 es moderado y la precisión es baja (11 %).
- **El umbral de decisión.** Balancear las clases cambia la decisión (recall alto, precisión baja) y las probabilidades no están calibradas; el umbral debería ajustarse al costo real de una falsa alarma.
- **Cambio de periodo.** La verificación temporal baja el AUC a 0,70-0,72: el modelo no es estable frente al cambio de reporte entre hojas y años.
- **Asociación no es causalidad.** Que Vichada o Arauca tengan más incendios grandes no significa que el departamento los cause. **Hipótesis (sin comprobar con estos datos):** la proporción alta en los llanos podría reflejar vegetación de sabana abierta, donde el fuego se propaga con facilidad, o diferencias en la capacidad de respuesta y de reporte. Requiere datos de vegetación, clima y respuesta.
- **El área es lo reportado.** La clase se define con el área informada, que puede variar entre hojas y años; los 775 eventos sin área no participan.

2.7 Cómo reproducirlo

Desde la raíz del repositorio (con el Python que trae Orange 3.40 para los dos últimos pasos):

```
python scripts/etapa6/preparar_supervisado.py
<carpeta de Orange>\python.exe scripts/etapa6/evaluar_supervisado.py
<carpeta de Orange>\python.exe scripts/etapa6/generar_flujo_supervisado.py
```

1. `preparar_supervisado.py` genera `data/etapa6/supervisado/incendios_supervisado.tab` (34.579 eventos).
2. `evaluar_supervisado.py` calcula, con las clases de aprendizaje de Orange, las métricas de las secciones 2.4.1 a 2.4.3 y las guarda en `data/etapa6/supervisado/metricas_esperadas.csv`.
3. Para ver el flujo, abrir `orange/supervisado/modelos_supervisados.ows` en Orange 3.40 (los datos se cargan con una ruta relativa). Los resultados de *Test and Score* coinciden con la tabla de las secciones 2.4.1 a 2.4.3.

2.8 Resumen para las conclusiones integradas

- **Hallazgo 1 (evidencia):** solo el 4,84 % de los incendios con área es grande (1.674 de 34.579); un modelo que siempre dijera "No grande" tendría 95,16 % de exactitud sin detectar ninguno, por lo que se evalúa con recall, precisión, F1 y AUC.

- **Hallazgo 2 (evidencia):** con año, mes, departamento y hoja de origen, la regresión logística balanceada alcanza AUC 0,772 y detecta el 69,4 % de los incendios grandes (1.161 de 1.674) con 9.274 falsas alarmas (precisión 11,1 %); el Random Forest obtiene AUC 0,774 y recall 62,2 %.
- **Hallazgo 3 (evidencia):** el departamento es la variable que más pesa. Las tasas más altas de incendios grandes son las de Vichada (25,8 %), Arauca (21,1 %), Casanare (15,8 %) y Meta (14,3 %), frente a 4,84 % general; por mes, marzo, febrero y septiembre (7,0 %, 6,6 % y 5,9 %).
- **Limitación:** con datos de 2023-2024 el AUC baja a 0,70-0,72; el modelo se apoya en pocas variables y el área es la reportada.
- **Hipótesis por validar:** que la alta proporción de incendios grandes en los llanos se deba a la vegetación de sabana abierta o a diferencias de respuesta; requiere datos de vegetación y clima.

3. Clustering

Autora: Camila Parra

3.1 Pregunta y objetivo

Pregunta: ¿qué grupos de departamentos comparten un mismo perfil de incendios de la cobertura vegetal en cuanto a intensidad, estacionalidad, extensión territorial y regularidad entre años?

Objetivo: descubrir perfiles de departamentos que no se ven en los conteos ni en las matrices de las Etapas 4 y 5, describir cada grupo de forma comprensible y proponer decisiones que podrían apoyarse en él.

El ejercicio no usa el área, las hectáreas, la clase de tamaño ni la variable "grande", porque son el objetivo del ejercicio supervisado.

3.2 Datos usados y transformaciones

- **Fuente:** `data/processed/incendios_ideam_tratado_2010_2024.csv`, con 35.355 eventos (BD-ICV, IDEAM, 2010-2024).
- **Script:** `scripts/etapa6/preparar_clustering.py`.
- **Unidad de análisis:** el departamento. Cada fila resume sus eventos de 2010 a 2024.

Paso	Filas
Eventos de entrada	35.355
Descartados sin departamento	43
Descartados con departamento pero sin año (1 de Cundinamarca, abril)	1
Eventos usados para el perfil	35.311
Departamentos	33
Excluidos por tener menos de 30 eventos con mes válido (Vaupés, 8 eventos)	1
Departamentos para el clustering	**32 (35.303 eventos)**

Cundinamarca queda con 5.937 eventos en lugar de los 5.938 del conjunto completo, porque se descarta el evento sin año.

Variables de agrupamiento:

Variable	Qué mide	Cálculo
`log10_eventos`	Intensidad	log10 del número de eventos con año. El logaritmo evita que Cundinamarca y Huila dominen la escala
`pct_t1`	Estacionalidad de enero a marzo	% de eventos de enero a marzo. **Denominador:** eventos con mes válido
`pct_t3`	Estacionalidad de julio a septiembre	% de eventos de julio a septiembre. Mismo denominador
`n_municipios`	Extensión territorial	Municipios distintos con al menos un evento
`cv_anual`	Regularidad entre años	Desviación estándar / media de los eventos por año en 2010-2024, contando los años con 0 eventos

`n_eventos` y `eventos_mes_valido` quedan como metadatos: sirven para leer los grupos, pero no participan en las distancias.

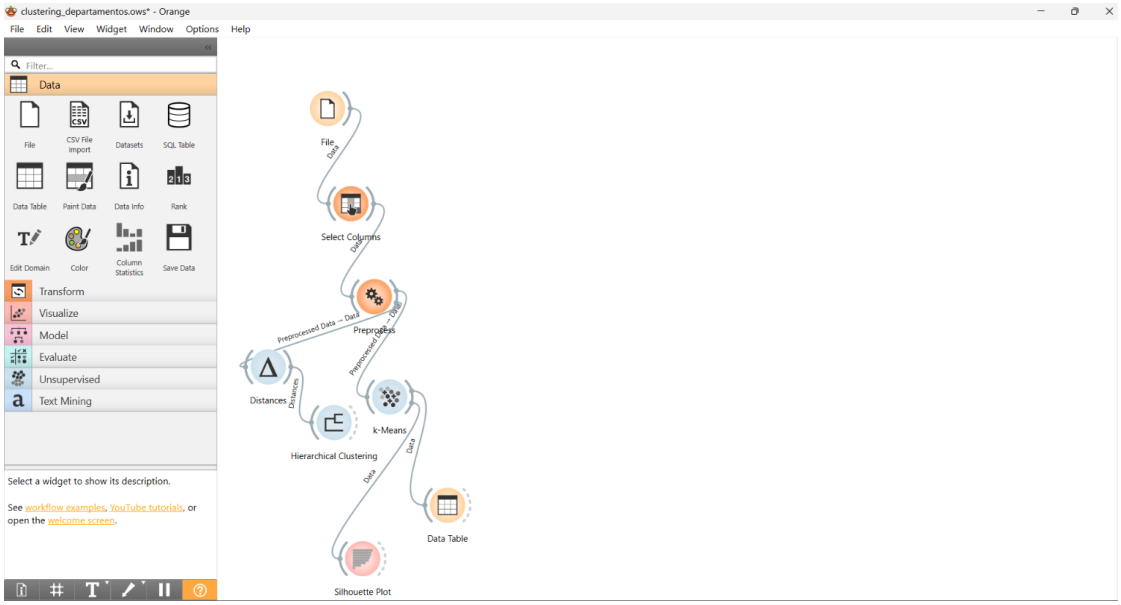
Exclusión de Vaupés: con 8 eventos, un solo incendio mueve sus porcentajes en 12,5 puntos, así que su perfil no es estable. Con el umbral de 30 eventos, cada evento mueve como máximo 3,3 puntos.

Estandarización: las variables tienen escalas muy distintas. Por ejemplo, `n_municipios` va de 1 a 126 y `cv_anual` de 0,57 a 2,57. Sin estandarizar, la variable con números más grandes dominaría la distancia euclidiana. Por eso todas se llevan a media 0 y desviación 1.

3.3 Flujo de Orange

Archivo: `orange/clustering/clustering_departamentos.ows` (Orange 3.40.0).

Figura 3.1. Flujo completo. La rama de k-Means elige el número de grupos y la rama jerárquica sirve para contrastar el resultado.

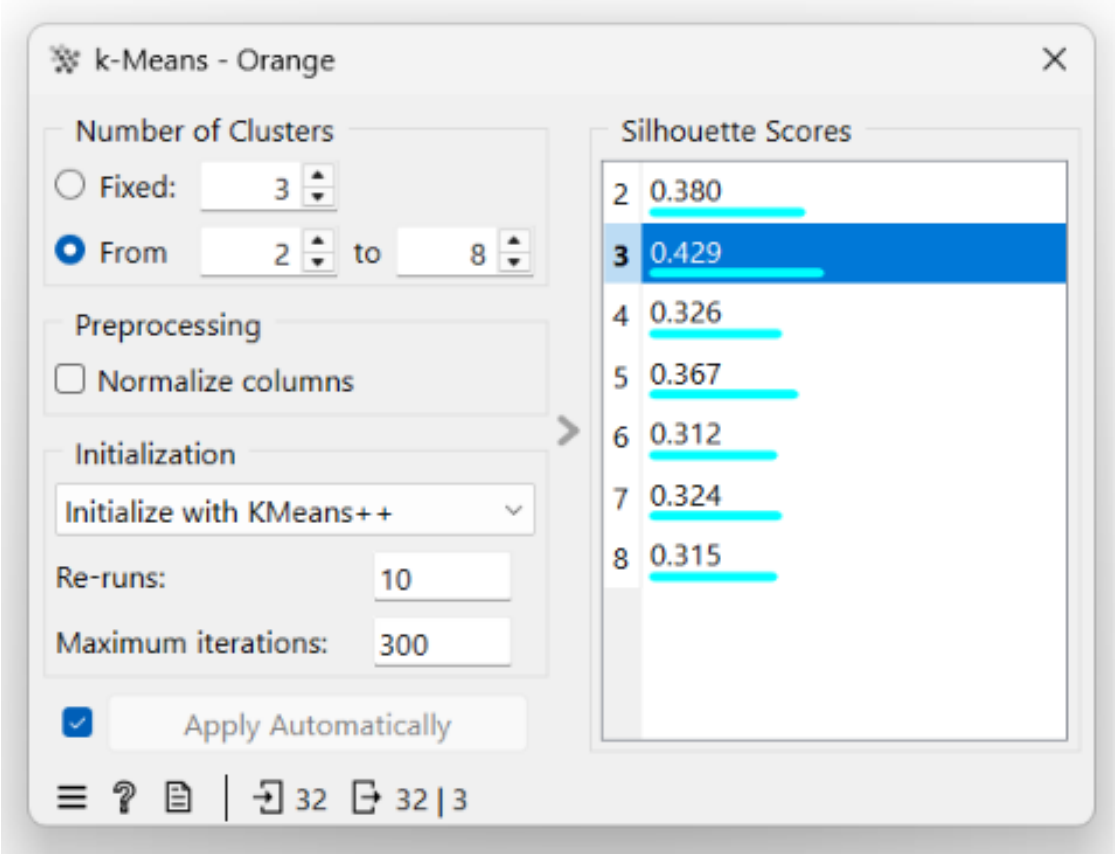


Widget	Conexión (de → a)	Parámetros
File	→ Select Columns	`data/etapa6/clustering/perfil_departamentos.csv`; 32 filas
Select Columns	File → Preprocess	Variables: `log10_eventos`, `pct_t1`, `pct_t3`, `n_municipios`, `cv_anual`. Metas: `departamento`, `n_eventos`, `eventos_mes_valido`. Sin variable objetivo
Preprocess	Select Columns → k-Means, Distances	Normalize Features: estandarizar a $\mu = 0$, $\sigma^2 = 1$
k-Means	Preprocess → Silhouette Plot, Data Table	k de 2 a 8; inicialización k-Means++; 10 repeticiones; 300 iteraciones como máximo; "Normalize columns" desmarcado porque los datos ya llegan estandarizados
Silhouette Plot	k-Means →	Distancia euclidiana; agrupado por Cluster
Data Table	k-Means →	Muestra el grupo asignado a cada departamento
Distances	Preprocess → Hierarchical Clustering	Euclidiana, sin normalizar (ya estandarizado)
Hierarchical Clustering	Distances →	Enlace Ward; anotaciones por `departamento`; selección Top N = 3

3.4 Resultados

3.4.1 Elección del número de grupos

Figura 3.2. Silueta promedio de k-Means para cada k. El mayor valor se obtiene con k = 3.

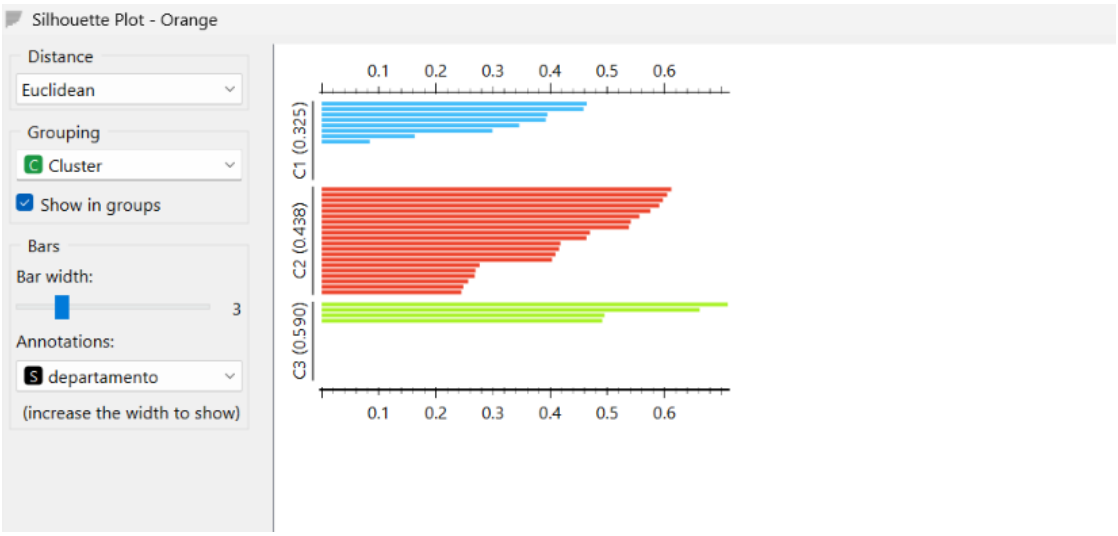


k	2	3	4	5	6	7	8
Silueta	0,380	**0,429**	0,326	0,367	0,312	0,324	0,315

Se elige **k = 3**, porque tiene la silueta más alta. Con más grupos la silueta baja, es decir, los grupos adicionales se separan peor. Una silueta de 0,429 indica una estructura de grupos razonable, aunque no muy marcada.

3.4.2 Calidad de cada grupo

Figura 3.3. Silueta de cada departamento. Cuanto más larga la barra, mejor encaja en su grupo. Ningún departamento tiene silueta negativa.

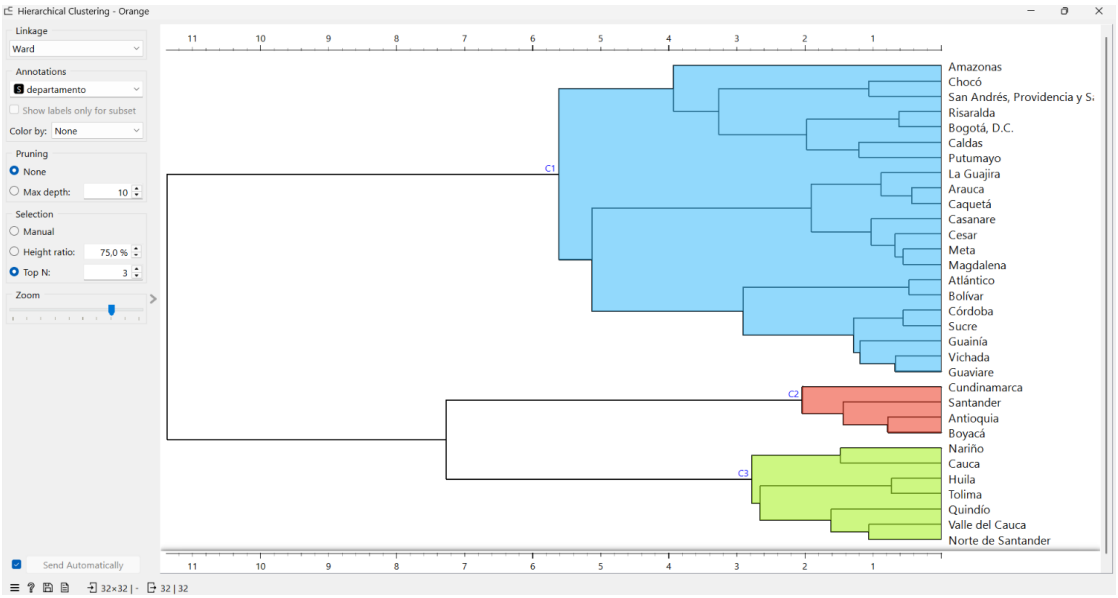


Grupo en Orange	Departamentos	Silueta del grupo
C3: Andinos grandes y extendidos	4	0,590
C2: Pico en enero-marzo	20	0,438
C1: Pico en julio-septiembre	8	0,325

El grupo andino es el más compacto. El de julio-septiembre es el más difuso, y su caso más débil es Amazonas.

3.4.3 Contraste con el clustering jerárquico

Figura 3.4. Dendrograma con enlace Ward, cortado en 3 grupos. La numeración de los grupos no coincide con la de k-Means; deben compararse por su contenido.



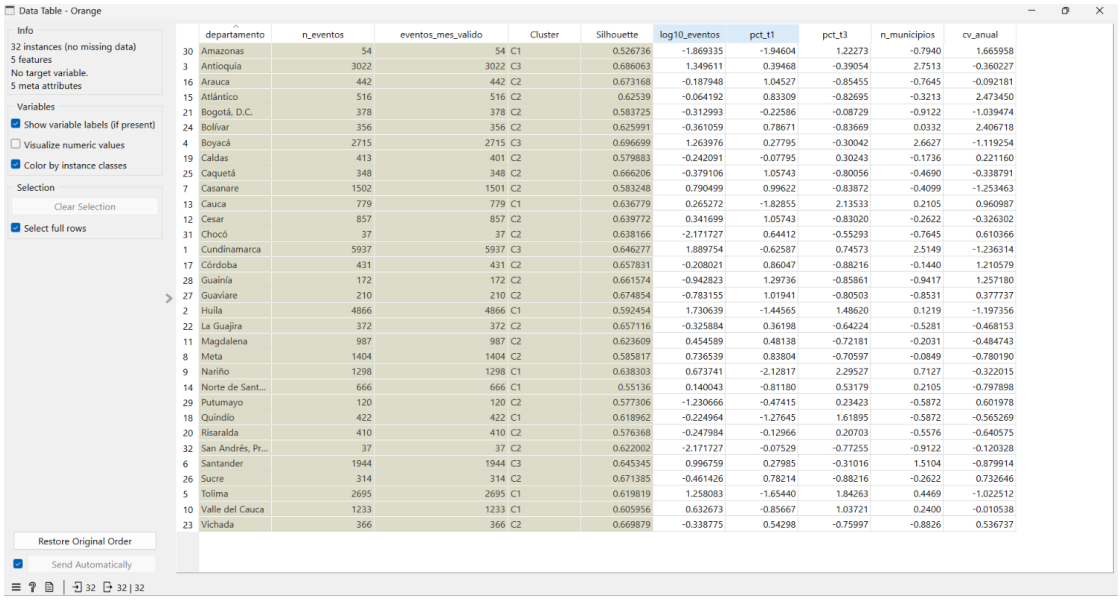
El jerárquico obtiene los mismos 3 grupos, con 21, 4 y 7 departamentos. La única diferencia es **Amazonas**, que pasa del grupo de julio-septiembre al de enero-marzo. El índice de Rand ajustado

entre ambos métodos es 0,891, calculado fuera de Orange con scikit-learn sobre los mismos datos estandarizados. Por eso los grupos son **estables frente al algoritmo**.

El dendrograma muestra además que los grupos andinos (grande y de julio-septiembre) se unen primero, cerca de 7 en la escala, y solo al final, cerca de 11,4, se unen con el grupo de enero-marzo. La separación principal está entre los departamentos con pico en enero-marzo y los andinos.

3.4.4 Caracterización de los grupos

Figura 3.5. Departamentos con el grupo asignado por k-Means. Las variables aparecen estandarizadas; la tabla siguiente usa los valores originales. La columna "Silhouette" de este widget es una aproximación por centroides y no se usa en el análisis.



	departamento	n_eventos	eventos_mes_valido	Cluster	Silhouette	log10_eventos	pct_t1	pct_t3	n_municipios	cv_anual
30	Amazonas	54	54	C1	0.526736	-1.869335	-1.94604	1.22273	-0.7940	1.665958
3	Antioquia	3022	3022	C3	0.686063	1.349611	0.39468	-0.39054	2.7513	-0.360227
16	Arauca	442	442	C2	0.673168	-0.187948	1.04527	-0.85455	-0.7645	-0.092181
15	Atlántico	516	516	C2	0.62539	-0.064192	0.83309	-0.82695	-0.3213	2.473450
21	Bogotá, D.C.	378	378	C2	0.583725	-0.312993	-0.22586	-0.08729	-0.9122	-1.039474
24	Bolívar	356	356	C2	0.625991	-0.361059	0.78671	-0.83669	0.0332	2.406718
4	Boyacá	2715	2715	C3	0.696699	1.263976	0.27795	-0.30042	2.6627	-1.119254
19	Caldas	413	401	C2	0.579883	-0.242091	-0.07795	0.30243	-0.1736	0.221160
25	Caquetá	348	348	C2	0.666206	-0.379106	1.05743	-0.80056	-0.4690	-0.338791
7	Casanare	1502	1501	C2	0.583248	0.790499	0.99622	-0.83872	-0.4099	-1.253463
13	Cauca	779	779	C1	0.636779	0.265272	-1.82855	2.13533	0.2105	0.960987
12	Cesar	857	857	C2	0.639772	0.341699	1.05743	-0.83020	-0.2622	-0.326302
31	Chocó	37	37	C2	0.638166	-2.171727	0.64412	-0.55293	-0.7645	0.610366
1	Cundinamarca	5937	5937	C3	0.646277	1.889754	-0.62587	0.74573	2.5149	-1.236314
17	Córdoba	431	431	C2	0.657831	-0.208021	0.86047	-0.88216	-0.1440	1.210579
28	Guainía	172	172	C2	0.661574	-0.942823	1.29736	-0.85861	-0.9417	1.257180
27	Guaviare	210	210	C2	0.674854	-0.783155	1.01941	-0.80503	-0.8531	0.377737
2	Huila	4866	4866	C1	0.592454	1.730639	-1.44565	1.48620	0.1219	-1.197356
22	La Guajira	372	372	C2	0.657116	-0.325884	0.36198	-0.64224	-0.5281	-0.468153
11	Magdalena	987	987	C2	0.623609	0.454589	0.48138	-0.72181	-0.2031	-0.484743
8	Meta	1404	1404	C2	0.585817	0.736539	0.83804	-0.70597	-0.0849	-0.780190
9	Nariño	1298	1298	C1	0.638303	0.673741	-2.12817	2.29527	0.7127	-0.322015
14	Norte de Sant...	666	666	C1	0.55136	0.140043	-0.81180	0.53179	0.2105	-0.797898
29	Putumayo	120	120	C2	0.577306	-1.230666	-0.47415	0.23423	-0.5872	0.601978
18	Quindío	422	422	C1	0.618962	-0.224964	-1.27645	1.61895	-0.5872	-0.565269
20	Risaralda	410	410	C2	0.576368	-0.247984	-0.12966	0.20703	-0.5576	-0.640575
32	San Andrés, Pr...	37	37	C2	0.622002	-2.171727	-0.07529	-0.77255	-0.9122	-0.120328
6	Santander	1944	1944	C3	0.645345	0.996759	0.27985	-0.31016	1.5104	-0.879914
26	Sucre	314	314	C2	0.671385	-0.461426	0.78214	-0.88216	-0.2622	0.732646
5	Tolima	2695	2695	C1	0.619819	1.258083	-1.65440	1.84263	0.4469	-1.022512
10	Valle del Cauca	1233	1233	C1	0.605956	0.632673	-0.85667	1.03721	0.2400	-0.010538
23	Vichada	366	366	C2	0.669879	-0.338775	0.54298	-0.75997	-0.8826	0.536737

Promedios con los valores originales (entre paréntesis, mínimo y máximo):

Grupo	Departamentos	Eventos (prom.)	% ene-mar	% jul-sep	Municipios	Variación anual
A. Andinos grandes y extendidos (C3)	4	3.405 (1.944-5.937)	66 % (48-75)	20 % (12-40)	113 (84-126)	0,76 (0,57-1,04)
B. Pico en julio-septiembre (C1)	8	1.502 (54-4.866)	25 % (8-43)	59 % (35-78)	35 (6-57)	1,15 (0,60-2,13)
C. Pico en enero-marzo, menos eventos (C2)	20	484 (37-1.502)	79 % (52-98)	7 % (0-29)	16 (1-34)	1,37 (0,57-2,57)

Grupo A. Andinos grandes y extendidos: Cundinamarca, Antioquia, Boyacá y Santander.

- Reúnen 13.618 eventos, el 38,6 % de los usados, con solo 4 departamentos.
- Lo que más los distingue es el número de municipios afectados (2,4 desviaciones sobre la media) y la intensidad.
- También son los más regulares entre años.
- Sus eventos se concentran en enero-marzo, pero con un segundo pico en julio-septiembre (20 % en promedio; 40 % en Cundinamarca).

- *Descripción:* incendios frecuentes, repartidos por casi todo el territorio y presentes todos los años.

Grupo B. Pico en julio-septiembre: Huila, Tolima, Nariño, Valle del Cauca, Cauca, Norte de Santander, Quindío y Amazonas.

- Reúnen 12.013 eventos (34,0 %).
- Lo que los distingue es la estacionalidad invertida: pocos eventos en enero-marzo (1,5 desviaciones bajo la media) y muchos en julio-septiembre (1,5 por encima).
- *Descripción:* departamentos andinos del sur y occidente cuya temporada de incendios es la de mitad de año.
- Amazonas queda en este grupo con poca seguridad: solo tiene 54 eventos.

Grupo C. Pico en enero-marzo, menos eventos: Casanare, Meta, Arauca, Vichada, Guaviare, Guainía, Caquetá, Putumayo, Magdalena, Cesar, Atlántico, Bolívar, Córdoba, Sucre, La Guajira, Caldas, Risaralda, Bogotá, Chocó y San Andrés.

- Reúnen 9.672 eventos (27,4 %).
- Casi 8 de cada 10 eventos ocurren en enero-marzo, con muy pocos en julio-septiembre.
- Tienen menos eventos, afectan pocos municipios y son los más irregulares entre años.
- *Descripción:* Llanos, Caribe y Amazonía, con una sola temporada de incendios a comienzos de año y años muy distintos entre sí.

3.5 Interpretación y aporte al problema

1. **El calendario divide al país en dos.** En la Etapa 5 se vio que Orinoquia concentra sus hectáreas en enero-marzo y Andina en julio-septiembre. El clustering muestra que esa diferencia no depende de la región administrativa: separa a los departamentos andinos en dos perfiles distintos (A y B). Huila y Tolima, que son andinos, se parecen más a Nariño y Cauca que a Cundinamarca o Boyacá.
2. **La extensión territorial es un perfil propio.** El grupo A no se distingue solo por tener muchos eventos, sino porque los incendios aparecen en más de 80 municipios por departamento y todos los años. Ese perfil no aparece al ordenar por conteos.
3. **Los departamentos con menos eventos son también los menos predecibles.** El grupo C combina una temporada muy marcada con años muy distintos entre sí. Por eso los promedios de pocos años sirven poco para planear en esos departamentos.

Decisiones que podría apoyar:

- Programar la preparación por perfil y no solo por región: antes de enero en el grupo C y en el A; antes de julio en el grupo B y como segunda temporada en el A.
- Reforzar la coordinación entre municipios en el grupo A, donde los eventos están dispersos por casi todo el territorio.
- Mantener capacidad flexible en el grupo C, donde la cantidad de eventos cambia mucho de un año a otro.

3.6 Limitaciones e hipótesis

- **Cambios en el reporte:** los perfiles describen los eventos reportados, no todos los incendios. El reporte cambia entre hojas de origen y años, y eso puede afectar sobre todo la variación anual.

- **Departamentos con pocos eventos:** Amazonas (54), Chocó (37) y San Andrés (37) tienen porcentajes inestables. Amazonas cambia de grupo según el algoritmo.
- **Calidad de la estructura:** una silueta de 0,429 indica grupos razonables pero no muy separados. El grupo B (0,325) es el más difuso.
- **Datos de Bogotá:** sus 2 municipios reflejan cómo se registró el nombre en los datos, no una división real.
- **Variables omitidas:** se omitieron causa y cobertura porque faltan en la mayoría de los eventos, y coordenadas y elevación porque son nulas en el 97 % de los casos.
- **Evidencia frente a hipótesis:** que existan los 3 perfiles es evidencia, porque se repite con dos algoritmos. Explicar los perfiles por el régimen de lluvias (dos temporadas secas en la zona andina, una en Llanos y Caribe) es una **hipótesis**: este análisis no usa datos climáticos.

3.7 Cómo reproducirlo

```
python scripts/etapa6/preparar_clustering.py
```

1. El script genera `data/etapa6/clustering/perfil_departamentos.csv` (32 departamentos) y `departamentos_excluidos.csv` (Vaupés).
2. Abre `orange/clustering/clustering_departamentos.ows` en Orange 3.40.0 o superior.
3. Orange guarda la ruta completa del CSV, porque los datos están fuera de la carpeta del flujo. En otro computador, abre el widget **File** y vuelve a elegir `data/etapa6/clustering/perfil_departamentos.csv`.
4. El widget k-Means debe mostrar la silueta 0,429 para k = 3.

3.8 Resumen para las conclusiones integradas

1. **Hay 3 perfiles de departamentos** (k = 3, silueta 0,429). Se repiten con el jerárquico Ward, con una sola diferencia (Amazonas) y un índice de Rand ajustado de 0,891.
    - *Interpretación:* los departamentos se agrupan por cuándo y dónde ocurren los incendios, no solo por cuántos tienen.
    - *Tipo:* evidencia.
2. **Grupo andino grande:** 4 departamentos (Cundinamarca, Antioquia, Boyacá y Santander) reúnen el 38,6 % de los eventos, con 113 municipios afectados en promedio y la menor variación anual (0,76).
    - *Interpretación:* el problema ahí es extendido y constante.
    - *Tipo:* evidencia.
3. **Grupo de julio-septiembre:** 8 departamentos (Huila, Tolima, Nariño, Valle del Cauca, Cauca, Norte de Santander, Quindío y Amazonas) tienen en promedio el 59 % de sus eventos en julio-septiembre.
    - *Interpretación:* la temporada no es igual en toda la zona andina, así que la preparación debe ajustarse por departamento.
    - *Tipo:* evidencia.
4. **Grupo de enero-marzo:** 20 departamentos de Llanos, Caribe y Amazonía concentran en promedio el 79 % de sus eventos en enero-marzo y tienen la mayor variación entre años (1,37).
    - *Tipo:* evidencia.
    - *Hipótesis por validar:* que la estacionalidad se deba al régimen de lluvias.

- **Limitación:** los perfiles describen eventos reportados, y el reporte cambia entre hojas de origen y años.

4. Conclusiones integradas

Elaborada con los resúmenes de las secciones 1, 2 y 3 y con un cruce de resultados entre las secciones 2 y 3.

4.1 Nuevos conocimientos

1. **Los incendios más grandes no están donde hay más incendios.** Al cruzar los tres perfiles de departamentos (clustering) con la proporción de incendios grandes (más de 100 ha, supervisado), el grupo andino grande (A) reúne el 38,5 % de los eventos con área, pero solo el 14,6 % de los incendios grandes (1,84 % de sus eventos). El grupo de pico en enero-marzo con menos eventos (C) reúne el 27,4 % de los eventos y el **55,3 % de los incendios grandes** (9,77 % de sus eventos).

Grupo (clustering)	Eventos con área	Grandes	% grandes	% de los eventos	% de los grandes
A. Andinos grandes y extendidos	13.301	245	1,84 %	38,5 %	14,6 %
B. Pico en julio-septiembre	11.759	504	4,29 %	34,1 %	30,1 %
C. Pico en enero-marzo, menos eventos	9.471	925	9,77 %	27,4 %	55,3 %
32 departamentos	**34.531**	**1.674**	**4,85 %**	100 %	100 %

2. **Dentro del grupo C, el tamaño se concentra en cinco departamentos, no en todo el grupo.** Vichada, Arauca, Casanare, Meta y Caquetá reúnen 663 de los 1.674 incendios grandes (39,6 %) con solo el 11,5 % de los eventos (3.988). El resto del grupo C tiene 4,78 % de incendios grandes (262 de 5.483), igual al promedio general (4,85 %). El grupo C incluye departamentos con casi ningún incendio grande (Risaralda 0,2 %, Bogotá 0,3 %, Atlántico 0,4 %, Guainía y Putumayo 0 %). Es decir, el calendario (enero-marzo) no basta para explicar el tamaño: el departamento pesa. Eso coincide con el modelo supervisado, donde el departamento es la variable más importante.
3. **El modelo supervisado sirve para priorizar, no para decidir.** Con año, mes, departamento y hoja de origen, la regresión logística balanceada detecta el 69,4 % de los incendios grandes (1.161 de 1.674; AUC 0,772), pero con una precisión de 11,1 % (9.274 falsas alarmas). Con datos de 2023-2024 el AUC baja a 0,70.
4. **Hay una brecha entre lo que se comenta y lo que se registra sobre las causas.** En 8 videos de YouTube, el 45 % de los comentarios (316 de 703; temas 2 y 3 de LDA) atribuye el incendio a una causa política o intencional, mientras el IDEAM solo registra la causa en el 11,7 % de los eventos (4.148 de 35.355) y no la registra en 2023-2024.
5. **Los videos analizados no tratan de los lugares donde se concentran los incendios grandes.** De los 8 videos, 4 se refieren a incendios en Tolima o en Jamundí (Valle del Cauca; grupo B), 2 a Villa de Leyva (Boyacá; grupo A) y 2 son generales. Ninguno trata de un departamento del grupo C (Llanos, Caribe y Amazonía).

4.2 Coincidencias y diferencias entre los análisis

	Qué muestra	Con qué coincide o difiere
Coincide	El departamento es la señal más fuerte: en el modelo supervisado es la variable principal y las tasas más altas son Vichada (25,8 %), Arauca (21,1 %), Casanare (15,8 %), Meta (14,3 %) y Caquetá (14,1 %).	Esos cinco departamentos están todos en el grupo C del clustering, que además concentra el 55,3 % de los incendios grandes.
Coincide	La estacionalidad: el modelo supervisado da más peso a septiembre una vez descontado el departamento, y el clustering separa un grupo con pico en julio-septiembre (B) y otro con pico en enero-marzo (C).	Es el patrón que ya se veía en las Etapas 4 y 5 para Orinoquia (enero-marzo) y Andina (julio-septiembre).
Difiere	El grupo A (Cundinamarca, Antioquia, Boyacá y Santander) tiene la mayor cantidad de eventos y los más regulares entre años, pero la menor proporción de incendios grandes (1,84 %).	Frecuencia y tamaño no van juntos.
Difiere	Los comentarios de YouTube (8 videos) se centran en incendios de la zona andina; los datos del IDEAM sitúan más de la mitad de los incendios grandes (55,3 %) en el grupo C (Llanos, Caribe y Amazonía).	La conversación pública y el registro apuntan a lugares distintos.
Difiere	Los comentarios dan por hecha la intencionalidad con mucha seguridad.	El registro técnico desconoce la causa en casi nueve de cada diez eventos.

4.3 Decisiones que podrían apoyarse

- **Priorizar la respuesta ante incendios extensos antes de enero** en Vichada, Arauca, Casanare, Meta y Caquetá, donde se concentra el 39,6 % de los incendios grandes del país con el 11,5 % de los eventos.
- **Preparar la zona andina por frecuencia y por temporada, no por tamaño:** antes de enero en el grupo A y antes de julio en el grupo B, sin dimensionarla como la zona de los incendios más extensos.
- **Usar el modelo como apoyo de priorización** (por ejemplo, ordenar departamentos y meses por riesgo), no como alarma automática: con una precisión de 11 %, el umbral debe ajustarse al costo real de una falsa alarma.
- **Mejorar el registro de la causa y de la cobertura.** Hoy faltan en la mayoría de los eventos y son justo lo que más se discute en la conversación pública.
- **Comunicar con cautela:** mientras no haya causa registrada, la atribución de intencionalidad que aparece en los comentarios no está respaldada por los datos.

4.4 Evidencia frente a hipótesis

Respaldado por evidencia	Hipótesis que requiere validación
El grupo C concentra el 55,3 % de los incendios grandes con el 27,4 % de los eventos (cruce de los grupos con el archivo supervisado).	Que la concentración en esos departamentos se deba a vegetación de sabana abierta o a diferencias en la respuesta y el reporte: no se usaron datos de vegetación, clima ni capacidad de respuesta.
El departamento es la variable que más pesa para predecir un incendio grande (AUC 0,772; recall 0,694; precisión 0,111).	Que el modelo se sostenga en el tiempo: con 2023-2024 el AUC baja a 0,70-0,72.
Existen 3 perfiles de departamentos, estables frente al algoritmo (k = 3, silueta 0,429; índice de Rand ajustado 0,891 frente al jerárquico).	Que la estacionalidad de cada perfil se deba al régimen de lluvias: no se usaron datos climáticos.
El 45 % de los comentarios (316 de 703) atribuye el incendio a una causa política o intencional; el IDEAM registra la causa en el 11,7 % de los eventos.	Que los incendios sean realmente provocados: es una percepción de quienes comentaron, no un hecho verificado.
El tono de los comentarios varía mucho por video (sentimiento promedio de +5,66 a −6,01).	Que ese tono dependa del enfoque editorial de cada cobertura: con 8 videos, no se puede separar del evento ni del canal.

4.5 Limitaciones del conjunto

- **Los datos del IDEAM describen eventos reportados**, y el reporte cambia entre hojas de origen y años; eso afecta a las secciones 2 y 3.
- **La muestra de YouTube es pequeña y sesgada:** 8 videos, uno de ellos (VANGUARDIA) con el 42,7 % de los comentarios, y son opiniones de quienes comentaron, no de toda la población.
- **Los periodos no coinciden:** los 8 videos se publicaron entre el 21 de agosto y el 20 de septiembre de 2026, y los datos del IDEAM llegan hasta 2024. El contraste entre comentarios y registro es de enfoque, no de los mismos incendios.
- **El cruce de las secciones 2 y 3 usa los 32 departamentos del clustering** (se excluye Vaupés, con 8 eventos, y los eventos sin departamento) y los eventos con área y año; es una asociación, no una causa.
- **Pocas variables:** causa y cobertura faltan en la mayoría de los eventos, y coordenadas y elevación son nulas en el 97 % de los casos.

4.6 Conclusión

El análisis de conocimiento oculto muestra que **el tamaño de un incendio se asocia más con dónde ocurre que con cuándo o con qué tan frecuentes sean los incendios**: cinco departamentos de Orinoquia y Amazonia (Vichada, Arauca, Casanare, Meta y Caquetá) concentran cerca del 40 % de los incendios grandes con una décima parte de los eventos, y los departamentos con más incendios (grupo andino) tienen la menor proporción de incendios grandes (1,84 %). Los comentarios de YouTube agregan algo que los datos no tienen, la narrativa pública sobre las causas, pero también muestran que esa narrativa se apoya en lugares y periodos distintos de los registrados. Las decisiones que se pueden respaldar con evidencia son de priorización territorial y de mejora del registro; las explicaciones climáticas o de intencionalidad siguen siendo hipótesis.

4.7 Cómo reproducir el cruce

```
python scripts/etapa6/cruce_resultados.py
```

Genera `data/etapa6/integracion/cruce_grupos_grandes.csv` y `cruce_departamentos.csv` a partir del archivo del ejercicio supervisado y de la pertenencia a los grupos del informe de clustering.

Referencias y enlaces

- Repositorio: https://github.com/sgora96/wildfire-data-mining
- Aplicación publicada: https://sgora96.github.io/wildfire-data-mining/
- Video de sustentación: https://youtu.be/eDYke3cpFs8
- Fuente de datos: BD-ICV, IDEAM, 2010-2024.